

智慧製造導論

Introduction to
Smart
Manufacturing

編著：李世淵
(機器人叫獸／ロボット教授)



TRADITION
MEETS
TECHNOLOGY
FOR A BRIGHTER
ISLAND

第八篇

可信製造、台灣案例與總整專題

篇章導讀：第八篇 可信製造、台灣案例與總整專題

走到第八篇，智慧製造的拼圖已經大致完整：設備與感測、通訊與數位孿生、MES 與精實、設計與製造技術、資料科學與工業 AI、企業 AI 與代理、Physical AI、服務、價值網路與永續。但還有兩個問題沒有回答。第一，這一切值得信任嗎？當工廠全面聯網、AI 參與決策，資安的破口與 AI 的失誤，都可能讓產線停擺、產品出錯、甚至危及人身安全。第二，這一切在真實的產業中長什麼樣子？讀者又要如何親手把它做出來？本篇由四章組成：前兩章談「可信」，第三章看「台灣」，最後一章「動手做」。

本篇要回答的問題

1. IT 與 OT 的資安有何不同？如何以區域與管道切分工廠網路、以白名單監測異常的通訊？遠端維護、備份與事件應變如何設計？SBOM 與模型的完整性驗證如何守住軟體與 AI 的供應鏈？AI 代理、機器人與數位孿生帶來哪些新的攻擊面？
2. 可信 AI 的原則在工廠中代表什麼？如何以 NIST AI RMF 與 ISO / IEC 42001 建立 AI 治理？模型卡、資料卡、紅隊測試與風險登錄如何落實？設計責任、智慧財產與法規遵循有哪些要點？人類最終責任、變更管理與持續稽核如何運作？
3. 台灣的晶圓代工、封裝測試、電子製造、工具機、中小企業與新創，各自從什麼痛點出發、如何運用本書的技術？
4. 如何在學習工廠中，把企業的問題轉化為 KPI、設計架構、開發 PoC、以統計方法證明效益，並完成文件、展示與答辯？

四章的分工

第 35 章〈OT 資安與供應鏈安全〉從 IT、OT、ICS、PLC 與 SCADA 的風險差異與歷史事件談起；以可達性分析說明 IEC 62443 區域與管道的網路切分效果，以白名單基準偵測未見過的通訊；說明身分管理、遠端維護與 3-2-1 備份，並以蒙地卡羅模擬比較備份策略對復原的影響；以 SBOM 為軟體元件的弱點排序，並驗證 AI 模型與資料的完整性；最後分析 AI 代理、機器人與數位孿生的攻擊

面，以物理一致性檢查偵測被竄改的資料。本章只談防禦，範例中的弱點與元件名稱皆為虛構。

第 36 章〈AI 治理與可信工業 AI〉以子群評測說明「整體正確率很高」可能隱藏某條產線的問題；以 NIST AI RMF 建立風險登錄，比較固有與剩餘風險；自動產生模型卡與資料卡，並以紅隊測試的壓力情境與驗收標準找出模型的弱點；整理設計責任、智慧財產與歐盟及我國的法規時程；最後以持續稽核檢查治理制度是否真的被執行。

第 37 章〈台灣智慧製造案例研究〉依產業鏈走一趟台灣：以可重入產線的模擬說明晶圓廠的負荷、派工與 AMHS 搬運；以封測的追溯粒度計算圍堵範圍，並以貝氏最佳化減少打線參數的實驗；說明電子製造的「模擬先行」與工具機的熱變位補償；估算中小企業分階段導入的效益與回收期；最後談無人機、機器人與積層製造新創從原型走向量產的挑戰。企業的資料均依公開報導與資料整理。

第 38 章〈總整專題：學習工廠實作〉是全書的收尾。本章以一條五站的教學產線，建立基準模型並找出瓶頸；從企業出題中定義 KPI，計算證明改善所需的量測天數；設計數位主線、學生與 AI 模組的架構，由事件計算 KPI 並進行追溯；在學生中比較改善方案、在學習工廠中試行並以信賴區間呈現效益；以要徑法規劃專題的時程；最後談技術文件、公開展示、答辯與反思。



圖 VIII-1 第八篇四章的學習主線

本篇在全書中的位置

第八篇是全書的總結與出口。前兩章為前七篇的成果加上「信任」的護欄：第 11 章的聯網與邊緣、第 26 章的遠端運維與第 32 章的機台雲，都需要第 35 章的區域切分、遠端存取管理與備援；第 22~31 章的工業 AI、企業 AI、代理與 Physical AI，都需要第 36 章的子群評測、紅隊測試、模型卡

與變更管理。第 37 章則把全書的技術放回台灣的產業脈絡，讓讀者看見派工（第 27 章）、追溯（第 17、20 章）、製程最佳化（第 25 章）、數位孿生（第 19~21 章）與服務化（第 32 章）如何在不同的產業中組合。第 38 章最後把所有的工具交給讀者：從量測、理解、決策、行動到再量測，親手完成一個循環。

貫穿本篇的主題是「可信與可證明」：資安讓系統在攻擊與故障下仍然可用；治理讓 AI 的限制、責任與變更被看見；案例研究區分企業的宣稱與可查證的事實；總整專題則要求效益以足夠的量測與信賴區間來證明。這些態度，與任何一項技術同樣重要。

閱讀建議

第 35、36 章的內容偏向制度與管理，但本書刻意把它們寫成可以計算的模型：可達路徑的數量、備份策略的復原時間、子群的校準誤差、風險分數、壓力測試的驗收結果。建議讀者實際修改這些程式的假設，觀察結論如何改變——例如資料只有 150 筆的產線、只量三天的試行、不含環境溫度的補償模型。資安的範例只用於防禦與教學，請勿在未經授權的系統上進行任何測試。

第 37 章適合作為課堂討論的材料：每一節選一家企業，請學生蒐集公開資料，區分企業的宣稱與可查證的事實，並對應到本書的章節。第 38 章則是整門課的總整：建議在學期初就讓學生分組、接觸出題的企業，在學期中依要徑完成基準量測與架構設計，學期末完成試行、文件與展示。課堂教學時，第 35~37 章建議各約一週，第 38 章則貫穿整個學期的專題。

實作方面，建議至少完成以下四項：第 35 章的區域與管道切分或白名單監測、第 36 章的子群評測與模型卡、第 37 章的晶圓廠派工模擬或工具機熱補償、第 38 章的量測天數計算與孿生方案比較。本篇的程式只需要 NumPy、SciPy、scikit-learn 與 NetworkX 等常用套件。相關範例程式將於本書的實驗倉庫中維護。

對高中 AI 機器人社團而言，第 36 章的「整體正確率隱藏子群問題」可以用社團自己訓練的影像辨識模型實驗；第 38 章的要徑法與量測天數，則適用於任何一個社團專題的規劃——先想清楚怎麼證明它有效，再開始寫程式。

讀完本篇，也讀完了全書。建議你回到第 1 章的那個問題：什麼是智慧製造？現在你的答案，應

該不只是一串技術的名詞，而是一個持續「量測、理解、決策、行動、再量測」的循環，以及讓這個循環可信、可證明、可延續的能力。

表 VIII-1 第八篇目錄

章	節
第 35 章 OT 資安與供應鏈安全	35.1 IT、OT、ICS、PLC 與 SCADA 的風險差異
	35.2 IEC 62443 區域與管道、零信任與網路監測
	35.3 身分管理、遠端維護、備援與事件應變
	35.4 SBOM、模型與資料來源的供應鏈安全
	35.5 AI 代理、機器人與數位孿生的攻擊面
第 36 章 AI 治理與可信工業 AI	36.1 安全、可靠、公平、透明、隱私與問責
	36.2 NIST AI RMF 與 ISO / IEC 42001
	36.3 模型卡、資料卡、紅隊測試與風險登錄
	36.4 設計責任、智慧財產與法規遵循
	36.5 人類最終責任、變更管理與持續稽核
第 37 章 台灣智慧製造案例研究	37.1 晶圓代工：虛擬晶圓廠、AMHS、先進封裝與智慧派工
	37.2 封裝測試：追溯、智慧物流與 AI 製程最佳化
	37.3 電子製造與工具機：數位孿生、AI 視覺與設備聯網
	37.4 中小企業：從單機聯網到閉環控制
	37.5 無人機、機器人與積層製造新創
第 38 章 總整專題：學習工廠實作	38.1 學習工廠的教學理念與場域設計
	38.2 企業出題：需求、現況與 KPI 定義
	38.3 架構設計：數位主線、孿生與 AI 模組
	38.4 PoC 開發、驗證與效益評估
	38.5 技術文件、公開展示、答辯與反思

第八篇 可信製造、台灣案例與總整專題

第 35 章

OT 資安與供應鏈安全

編著 李世淵（機器人叫獸） | 助教 李天宇、李宇晴

本章重點

- IT、OT、ICS、PLC 與 SCADA 的風險差異與歷史事件
- IEC 62443 區域與管道：網路切分的可達性分析；白名單式網路監測
- 身分管理、遠端維護、3-2-1 備份與事件應變
- SBOM 弱點排序與 AI 模型、資料的完整性驗證
- AI 代理、機器人與數位孿生的攻擊面；以物理一致性檢查資料

叫獸開講：資安人員最怕聽到的一句話

我曾經在一家工廠的資安會議上，聽到設備課長很有把握地說：「我們的機台都沒有連網，很安全。」資安人員拿出一張網路拓撲圖，問了幾個問題：機台的 HMI 有沒有接到 MES？工程師有沒有用隨身碟下載程式？設備商有沒有遠端連線幫忙維修？課長想了想：「這些都有.....可是那些不算連網吧？」

那些當然都算。後來的盤點發現，所謂「沒有連網」的產線，其實有好幾條路可以通到辦公室的網路：一台雙網卡的工程站、一個設備商留下的遠端連線工具、一台多年沒有更新的 HMI。更麻煩的是，產線的電腦大多使用老舊的作業系統，不能隨便更新，因為更新後設備可能無法運作；也不能隨便裝防毒軟體，因為怕影響即時性。

我們沒有試圖一次解決所有問題，而是先做了三件事：畫出真正的資產與網路地圖；依功能把網路切成幾個區域，只在區域之間開放必要的通道；把設備商的遠端連線集中到一個有多因子驗證、需要事先申請、全程錄影的閘道。接著才是監測、備份與事件演練。一年後，工廠遇到一次勒索軟體攻擊，辦公室的檔案伺服器被加密了，但產線一分鐘都沒有停——因為那條路已經被切斷了。

OT 資安的核心不是買最貴的防火牆，而是理解工廠的特性：可用性與安全性優先、設備生命週期長、更新困難、人員與設備商的協作複雜。這一章，我們從 IT 與 OT 的風險差異談起；介紹 IEC 62443 的區域與管道、零信任與網路監測；說明身分管理、遠端維護、備援與事件應變；討論 SBOM、模型與資料來源的供應鏈安全；最後談 AI 代理、機器人與數位孿生帶來的新攻擊面。

（說明：本節情境由作者綜合產業輔導經驗與公開案例改寫，人物與細節已調整。）

學習目標

讀完本章後，你應該能夠：

1. 說明 IT 與 OT 在資安目標、系統特性與風險上的差異，以及 ICS、PLC 與 SCADA 的角色。
2. 說明 IEC 62443 的區域與管道概念，並以可達性分析評估網路切分的效果。
3. 說明零信任與 OT 網路監測的原理，並以白名單基準偵測異常的通訊。

4. 設計身分管理、遠端維護、備援與事件應變的機制，並評估備份策略對復原的影響。
5. 以 SBOM 管理軟體元件的弱點，並驗證 AI 模型與資料的來源與完整性。
6. 分析 AI 代理、機器人與數位孿生的攻擊面，並以物理一致性檢查偵測資料異常。

核心概念

表 35-1 本章核心名詞中英對照

中文名詞	英文	一句話說明
營運技術	Operational Technology, OT	監控與控制實體設備與製程的硬體與軟體
工業控制系統	Industrial Control System, ICS	包括 PLC、DCS、SCADA 等控制系統的總稱
可程式邏輯控制器	Programmable Logic Controller, PLC	執行現場控制邏輯的工業控制器
監控與資料擷取	SCADA	集中監控分散的設備與製程
區域與管道	Zones and Conduits	依安全需求把系統分區，只在區域間開放受控的通道
安全等級	Security Level, SL	IEC 62443 中描述防護能力的等級
零信任	Zero Trust	不因網路位置而信任，每次存取都需驗證與授權
縱深防禦	Defense in Depth	以多層防護降低單一防線失效的影響
網路監測	Network Security Monitoring	被動監聽流量以偵測異常與威脅
軟體物料清單	Software Bill of Materials, SBOM	列出軟體所含元件與版本的清單
復原時間目標	Recovery Time Objective, RTO	中斷後恢復服務的目標時間
復原點目標	Recovery Point Objective, RPO	可接受的最大資料損失時間
事件應變	Incident Response	偵測、圍堵、根除、復原與檢討的流程
攻擊面	Attack Surface	系統可能被攻擊的所有入口

35.1 IT、OT、ICS、PLC 與 SCADA 的風險差異

35.1.1 IT 與 OT 的差異

資訊技術 (IT) 處理資料，營運技術 (OT) 控制實體世界。兩者的資安目標排序不同：IT 傳統上以機密性為首，OT 則以可用性與人身安全為首——工廠寧可資料外洩，也不能讓反應器失控或產線長時間停擺。這個差異影響了所有的資安決策。

表 35-2 IT 與 OT 的資安差異

面向	IT	OT
優先目標	機密性、完整性、可用性	人身安全、可用性、完整性、機密性
系統生命週期	3~5 年	15~30 年
更新與修補	定期、自動化	需停機與驗證，常延後或無法修補
即時性要求	一般可容忍延遲	毫秒級的控制，掃描或防毒可能影響運作
通訊協定	標準 IT 協定，多有加密與驗證	Modbus 等工業協定，早期多無驗證
異常的後果	資料外洩、服務中斷	設備損壞、產品報廢、環境污染、人員傷亡
管理者	資訊部門	生產、設備、廠務與設備商

35.1.2 ICS、PLC 與 SCADA

工業控制系統 (ICS) 包括現場的 PLC 與安全控制器、流程工業的分散式控制系統 (DCS)，以及監控多個站點的 SCADA；上面還有 HMI、工程站、歷史資料庫與 MES (第 11、17 章)。傳統的 Purdue 參考模型把這些系統分成多個層級，從現場設備、控制、監控、營運到企業，也成為 IEC 62443 區域劃分的參考。

OT 的歷史事件提醒我們風險是真實的：依公開資料，2010 年被發現的 Stuxnet 蠕蟲針對特定的 PLC 竄改控制邏輯；2015 年烏克蘭電網遭攻擊造成大範圍停電；2017 年被揭露的 TRITON 惡意程式以安全儀表系統為目標；2021 年美國一家輸油管線公司的 IT 系統遭勒索軟體攻擊，公司為避免擴散而主動停止管線運作。台灣也曾有晶圓代工廠在 2018 年因新機台安裝時帶入勒索蠕蟲的變種而導致部分產線停機。這些事件的共同點是：IT 與 OT 之間的界線、可攜式媒體、設備商與供應鏈，常是入

侵的途徑；而 OT 的影響往往不是資料，而是生產與安全。

35.2 IEC 62443 區域與管道、零信任與網路監測

35.2.1 IEC 62443

IEC 62443 是工業自動化與控制系統資安的國際標準系列，涵蓋資產擁有者的政策與程序、系統整合者的系統設計，以及產品供應商的元件安全與安全開發流程。它的核心概念之一是「區域與管道」：把具有相同安全需求的資產劃為一個區域，區域之間只能透過受控的管道通訊；每個區域依風險評估訂定目標安全等級（SL 1~4），再選擇相應的防護措施。美國 NIST 的 SP 800-82（2023 年發布第 3 版，更名為 OT 安全指南）也是常用的參考。

35.2.2 範例：網路切分的可達性分析

下面的程式以圖論分析一座工廠的網路：在扁平網路中，任何兩台設備都能互通，設備商的遠端桌面直接連進工程站；切分後，依企業區、DMZ、營運區、控制區與現場區劃分，只開放 15 條必要的管道，安全 PLC 與其他網路隔離。比較辦公電腦與外部廠商能「碰到」多少現場設備：

```
import networkx as nx
# 區域與管道：工廠網路的可達性分析。比較「扁平網路」與依 IEC 62443 概念切分區域、只開放必要管道之後，辦公室電腦與外部遠端連線能「碰到」多少控制設備
def build(segmented):
    G = nx.DiGraph()
    zones = {"企業區": ["辦公電腦", "ERP"], "DMZ": ["歷史資料庫鏡像", "遠端存取閘道"], "營運區": ["MES", "歷史資料庫", "工程站"],
            "控制區": ["SCADA", "HMI-1", "HMI-2"], "現場區": ["PLC-1", "PLC-2", "安全 PLC", "機器人控制器"]}
    nodes = {n: z for z, ns in zones.items() for n in ns}; nodes["外部廠商"] = "網際網路";
    G.add_nodes_from(nodes)
    if not segmented:
        # 扁平網路：任意兩台都能互通
        for a in nodes:
            for b in nodes:
                if a != b and a != "外部廠商" and b != "外部廠商": G.add_edge(a, b)
        G.add_edge("外部廠商", "工程站")
        # 廠商以遠端桌面直接連進工程站
    else:
        # 只開放必要的管道（單向或指定服務）
        conduits = [("辦公電腦", "ERP"), ("ERP", "MES"), ("MES", "歷史資料庫"), ("歷史資料庫", "歷史資料庫鏡像"), ("辦公電腦", "歷史資料庫鏡像"),
                    ("外部廠商", "遠端存取閘道"), ("遠端存取閘道", "工程站"), ("工程站", "SCADA"), ("SCADA", "HMI-1"), ("SCADA", "HMI-2"),
                    ("SCADA", "PLC-1"), ("SCADA", "PLC-2"), ("工程站", "PLC-1"), ("工程站", "PLC-2"), ("SCADA", "機器人控制器")]
```

```

G.add_edges_from(conduits)                                     # 安全 PLC 不與其他網路
連接（獨立的安全系統）
return G, nodes
for seg in (False, True):
    G, z = build(seg); field = [n for n in z if z[n] == "現場區"]
    for src in ("辦公電腦", "外部廠商"):
        reach = [n for n in field if nx.has_path(G, src, n)]
        hops = [nx.shortest_path_length(G, src, n) for n in reach]
        print(f"{'切分後' if seg else '扁平網路'}: {src} 可達現場設備
{len(reach)}/{len(field)} 台" + (f", 最少需經過 {min(hops)} 跳" if hops else ""))
G, z = build(True); print("切分後的管道數:", G.number_of_edges(), "; 安全 PLC 可達:",
any(nx.has_path(G, s, "安全 PLC") for s in G if s != "安全 PLC"))

```

執行結果：扁平網路中，辦公電腦可以直接（1 跳）碰到全部 4 台現場設備，外部廠商經由工程站 2 跳即可到達；切分後，辦公電腦完全無法到達現場設備，外部廠商仍可經由遠端存取閘道、工程站到達 3 台設備（至少 3 跳），而安全 PLC 無法從任何地方到達。




圖 35-1 扁平網路與區域管道切分的對比

切分並不是把所有路徑都切斷——工廠仍然需要設備商的遠端維修、需要 MES 與控制層交換資料。關鍵在於每一條保留的路徑都是「刻意的、受控的、被監測的」：外部廠商的那條路必須經過有多因子驗證、事先申請、時間限制與全程錄影的閘道（35.3 節）；而安全系統應保持獨立，不因生產的便利而連接。

35.2.3 零信任與網路監測

零信任的原則是「永不信任、始終驗證」：不因為連線來自內部網路就信任它，每一次存取都依身分、設備狀態與情境驗證與授權。在 OT 中全面實施零信任並不容易——許多設備不支援現代的驗證機制——因此常以區域邊界的閘道、跳板主機與身分感知的存取控制來實現。

OT 網路的流量高度規律：固定的主機、固定的協定與功能、固定的輪詢週期。這讓「白名單」

式的網路監測特別有效：先學習正常的通訊組合，再對任何新的通訊對象、未預期的寫入或程式下載發出警報。監測以被動的方式複製交換器的流量，不影響控制系統的運作。

下面的程式模擬一天的正常流量建立基準（SCADA 每秒輪詢兩台 PLC、HMI 偶爾寫入設定值、歷史資料庫定期讀取），再監測一段包含三個異常事件的 2 小時流量：

```
import numpy as np
from collections import Counter
# OT 網路監測：工控流量高度規律（固定的主機、功能碼與週期）。以「白名單基準」學習正常的通訊組合與輪詢週期，偵測新的通訊對象、未預期的寫入指令與時序異常
rng = np.random.default_rng(2)
def traffic(hours, events=()):
    recs = [] # （時間秒，來源，目的，功能）
    for t in np.arange(0, hours * 3600, 1.0): # SCADA 每秒輪詢兩台 PLC（讀取）
        recs += [(t + rng.normal(0, 0.02), "SCADA", "PLC-1", "讀取"), (t + 0.5 + rng.normal(0, 0.02), "SCADA", "PLC-2", "讀取")]
        for t in rng.uniform(0, hours * 3600, int(hours * 4)): # 操作員從 HMI 偶爾寫入設定值
            recs.append((t, "HMI-1", "PLC-1", "寫入設定值"))
        for t in np.arange(0, hours * 3600, 900.0): recs.append((t, "歷史資料庫", "SCADA", "讀取"))
    recs += list(events); return sorted(recs)
base = traffic(24) # 以 24 小時的正常流量建立基準
allow = Counter((s, d, f) for _, s, d, f in base)
def periods(recs, s, d):
    t = np.array([r[0] for r in recs if r[1] == s and r[2] == d and r[3] == "讀取"]);
    return np.diff(t)
ref = periods(base, "SCADA", "PLC-1"); mu, sd = ref.mean(), ref.std()
def detect(recs):
    alerts = [f"{t:7.0f}s 未見過的通訊：{s} → {d} ({f})" for t, s, d, f in recs if (s, d, f) not in allow]
    p = periods(recs, "SCADA", "PLC-1"); z = np.abs(p - mu) / sd
    if np.mean(z > 4) > 0.01: alerts.append(f"輪詢週期異常：{np.mean(z > 4):.1%} 的間隔偏離基準超過 4 個標準差")
    return alerts
test = traffic(2, events=[(1800, "工程站", "PLC-2", "下載程式"), (4000, "辦公電腦", "PLC-1", "讀取"), (5000, "HMI-1", "安全 PLC", "寫入設定值")])
print(f"基準：{len(base):,} 筆通訊，{len(allow)} 種組合")
for a in detect(test): print("警報：" + a)
calm = traffic(2); print(f"正常的 2 小時流量：警報 {len(detect(calm))} 則")
```

執行結果：基準有約 17 萬筆通訊，只有 4 種組合。測試流量中的三個事件都被偵測：工程站對 PLC-2 下載程式、辦公電腦直接讀取 PLC-1、HMI-1 對安全 PLC 寫入設定值；正常的 2 小時流量沒有任何警報。




圖 35-2 OT 流量的白名單基準與異常事件

白名單監測的誤報很少，但它也會對「合法但不常見」的操作發出警報，例如工程師依變更流程下載新程式。因此監測系統應與變更管理（第 36 章）結合：經核准的變更事先登錄，監測時自動比對；未經登錄的程式下載，才是需要立即處理的事件。

35.3 身分管理、遠端維護、備援與事件應變

35.3.1 身分與存取管理

OT 環境常見的身分問題包括：多人共用的帳號與密碼、設備出廠的預設密碼從未更改、離職人員與設備商的帳號未停用、工程站擁有對所有 PLC 的完整權限。改善的方向是：每個人與每個系統都有自己的身分；依角色給予最小權限（第 29 章）；重要的操作（例如下載 PLC 程式、修改安全參數）需要額外的核准；定期盤點與停用帳號；並留下可稽核的紀錄。

35.3.2 遠端維護

設備商的遠端維護是工廠營運的必要服務（第 26、32 章），也是 OT 最常見的入侵途徑之一。安全的遠端維護應包括：集中的遠端存取閘道，禁止設備商自行安裝遠端連線工具；多因子驗證；事先申請、限定時間與範圍的存取；連線全程錄影；必要時由廠內人員陪同或確認關鍵操作；以及結束後自動中斷連線。第 26 章討論的「單向資料送出」，也是降低風險的常見做法。

35.3.3 範例：備份策略與復原

勒索軟體是製造業最常見的重大資安事件之一。即使控制層沒有被直接攻擊，營運區的 MES、歷

史資料庫與工程站被加密，也可能讓工廠無法排程、追溯與調整設備，被迫停線。下面的程式以蒙地卡羅模擬比較三種備份策略的停線時間（RTO）與資料損失（RPO）。各種情境的時間與機率都是示意的假設：

```
import numpy as np
# 備援與復原：勒索軟體加密了營運區的伺服器（MES、歷史資料庫、工程站）。比較三種備份策略的停線時間（RTO）與資料損失（RPO），以蒙地卡羅模擬攻擊發生的時間與備份是否也被波及
rng = np.random.default_rng(4)
N = 20000
def recover(strategy):
    t_attack = rng.uniform(0, 24, N) # 攻擊發生在一天中的任意時刻（每天 0 時做每日備份）
    if strategy == "無離線備份（只有同網段的備份）":
        hit = rng.random(N) < 0.7 # 70% 的機率備份伺服器一起被加密
        rto = np.where(hit, rng.uniform(72, 240, N), rng.uniform(24, 48, N)); rpo = np.where(hit, rng.uniform(24 * 7, 24 * 30, N), t_attack)
    elif strategy == "每日離線備份":
        rto = rng.uniform(24, 48, N); rpo = t_attack # 從離線備份還原，損失當天的資料
    else:
        # 3-2-1+不可變更備份+演練過的復原手冊、PLC 程式黃金映像
        rto = rng.uniform(8, 16, N); rpo = np.minimum(t_attack, rng.uniform(0, 1, N)) # 加上每小時的不可變更快照
    return rto, rpo
for s in ("無離線備份（只有同網段的備份）", "每日離線備份", "3-2-1+不可變更快照+演練"):
    rto, rpo = recover(s)
    print(f"{s}：停線時間 平均 {rto.mean():.0f} 小時（P95 {np.percentile(rto, 95):.0f}），資料損失 平均 {rpo.mean():.1f} 小時（P95 {np.percentile(rpo, 95):.0f}）")
```

執行結果：若只有與伺服器同網段的備份，備份有很大的機率一起被加密，平均停線約 121 小時（最差 5% 約 229 小時），資料損失平均約 314 小時——必須回到更早的備份或重建；每日離線備份平均停線約 36 小時、資料損失約 12 小時；3-2-1 備份（三份資料、兩種媒體、一份離線或異地）加上每小時的不可變更快照與演練過的復原手冊，平均停線約 12 小時、資料損失約 0.5 小時。




圖 35-3 三種備份策略的停線時間與資料損失

備份的價值只有在「還原成功」時才會顯現。實務上常見的失敗包括：備份從未測試過還原、備份伺服器與生產網路共用帳號、PLC 程式與設備參數沒有備份、復原需要的軟體授權與安裝檔找不到。對 OT 而言，PLC 與機器人程式、HMI 畫面、設備參數與網路設定的「黃金映像」，與伺服器的資料同樣重要。

35.3.4 事件應變

事件應變通常包括準備、偵測與分析、圍堵、根除、復原與事後檢討。OT 的事件應變有幾個特別的考量：圍堵時要評估「切斷網路」對生產與安全的影響，必要時改以手動或安全的模式運轉；安全系統必須保持獨立運作；證據保存與生產恢復之間要取得平衡；並且要事先與設備商、資安服務商與主管機關建立聯繫管道。定期的桌上演練，讓生產、設備、資訊與管理階層在事件發生前就知道各自的角色。我國《資通安全管理法》在 2025 年修正，強化了特定非公務機關的資安人員配置、委外管理與重大事件的支援機制，關鍵基礎設施的業者尤其需要注意相關義務。

35.4 SBOM、模型與資料來源的供應鏈安全

35.4.1 軟體供應鏈

工廠中的每一台設備都包含大量的軟體元件：作業系統、通訊函式庫、網頁介面、開源套件。當某個常用元件被發現弱點時，第一個問題是：「我們有哪些設備用了它？」軟體物料清單 (SBOM) 列出產品包含的元件與版本，讓這個問題可以快速回答。美國在 2021 年 5 月的第 14028 號行政命令中推動軟體供應商提供 SBOM；歐盟的《網路韌性法》(Cyber Resilience Act, 2024 年 12 月生效) 要求具數位元素的產品符合資安要求，製造商對已被利用的弱點與重大事件的通報義務自 2026 年 9 月起適用，主要義務則自 2027 年 12 月起全面適用。

35.4.2 範例：SBOM 弱點比對與模型完整性

下面的程式以一份簡化的 SBOM 比對一份弱點清單——為避免誤導，這裡的弱點編號與受影響版本都是虛構的教學資料，與真實的軟體版本無關——並依嚴重度、是否已知被利用與是否對外暴露排序（元件名稱也以虛構的通用名稱表示）；接著以雜湊值驗證 AI 模型與訓練資料檔是否與發布時的清單一致：

```

import hashlib, json
# 軟體物料清單 (SBOM) 與模型來源驗證：比對元件版本與 (虛構的) 弱點清單，依嚴重度、是否已被利用與暴露程度排序；再以雜湊值驗證 AI 模型與資料檔是否與簽署的清單一致
def ver(v): return tuple(int(x) for x in v.split("."))
SBOM = [{"name": "crypto-lib", "version": "3.0.7", "asset": "邊緣閘道器", "exposed": True},
        {"name": "modbus-lib", "version": "3.1.6", "asset": "邊緣閘道器", "exposed": False},
        {"name": "embedded-shell", "version": "1.33.1", "asset": "HMI 面板", "exposed": False},
        {"name": "script-runtime", "version": "3.11.4", "asset": "AI 推論伺服器", "exposed": False},
        {"name": "inference-runtime", "version": "1.15.0", "asset": "AI 推論伺服器", "exposed": False},
        {"name": "web-dashboard", "version": "2.4.0", "asset": "機台雲入口", "exposed": True}]
VULNS = [ # 教學用的虛構弱點：元件、受影響版本區間、CVSS 分數、是否已知被利用
        ("VULN-A", "crypto-lib", "3.0.0", "3.0.8", 7.5, False), ("VULN-B", "embedded-shell", "1.30.0", "1.34.0", 6.5, False),
        ("VULN-C", "web-dashboard", "2.0.0", "2.5.1", 9.8, True), ("VULN-D", "inference-runtime", "1.10.0", "1.14.0", 8.1, False),
        ("VULN-E", "modbus-lib", "3.1.0", "3.1.7", 5.3, False)]
def match():
    out = []
    for c in SBOM:
        for vid, name, lo, hi, cvss, kev in VULNS:
            if c["name"] == name and ver(lo) <= ver(c["version"]) < ver(hi):
                pri = cvss + (3 if kev else 0) + (2 if c["exposed"] else 0) # 簡化的優先序：嚴重度+已被利用+對外暴露
                out.append((pri, vid, c["asset"], name, c["version"], cvss, kev, c["exposed"]))
    return sorted(out, reverse=True)
def sha(b): return hashlib.sha256(b).hexdigest()
for pri, vid, asset, n, v, cvss, kev, exp in match():
    print(f"優先序 {pri:4.1f} | {vid} | {asset} 的 {n} {v} | CVSS {cvss}{'| 已知被利用' if kev else ''}{'| 對外暴露' if exp else ''}")
model, data = b"weights-v3.2 ...", b"training-set-2026Q2 ..."
manifest = {"defect_model.onnx": sha(model), "train.parquet": sha(data)} # 發布時簽署的清單 (實務上再以數位簽章保護)
received = {"defect_model.onnx": b"weights-v3.2 ...(tampered)", "train.parquet": data}
for f, b in received.items(): print(f"{f}: {'一致' if sha(b) == manifest[f] else '雜湊不符，拒絕部署'}")

```

執行結果：4 個元件符合弱點的版本區間，優先序最高的是機台雲入口的網頁元件（嚴重度 9.8、已知被利用、對外暴露），其次是對外暴露的邊緣閘道器的加密函式庫；HMI 面板的嵌入式工具與 Modbus 函式庫的弱點優先序較低，可以排入計畫性的維護。AI 推論伺服器的元件版本不在受影響的區間內。模型檔的雜湊值與清單不符，被拒絕部署；資料檔一致。

這個排序方法反映了 OT 的現實：無法一次修補所有弱點，必須依風險決定先後。對無法立即修補的設備，可以採用補償措施——加強隔離、限制存取、加強監測——並追蹤到能夠修補為止。公開的已知被利用弱點清單（例如美國 CISA 維護的清單）是排定優先序的重要參考。

35.4.3 AI 模型與資料的供應鏈

AI 帶來新的供應鏈風險：從外部下載的預訓練模型可能被植入後門；訓練資料可能被污染（資料投毒），讓模型在特定條件下做出錯誤的判斷；模型檔的某些格式在載入時可能執行任意程式碼；第三方的模型服務可能改變版本或行為。對應的做法包括：只從可信的來源取得模型，並記錄來源與版本（第 36 章的模型卡）；以雜湊與數位簽章驗證模型與資料；使用不會執行程式碼的安全格式；在隔離環境中評測新模型；建立資料的血緣與存取控制（第 20、23 章）；以及在部署前後以評測題庫檢查模型的行為（第 28 章）。

35.5 AI 代理、機器人與數位學生的攻擊面

35.5.1 新的攻擊面

第六篇的 AI 代理、機器人與數位學生，讓工廠更聰明，也帶來新的攻擊面：

表 35-3 智慧製造新技術的攻擊面與防護

技術	可能的攻擊或失效	影響	防護
AI 代理（第 29 章）	提示注入、工具濫用、權限過大	錯誤的工單、採購或參數變更	最小權限、風險閘道、核准、稽核
企業 AI 大腦（第 28 章）	資料外洩、知識庫污染、越權查詢	機密外洩、錯誤的作業指引	檢索階段的權限過濾、文件版本與簽署
視覺與 AI 模型（第 24 章）	對抗樣本、資料投毒、模型竊取	漏檢、誤判、智財損失	資料與模型完整性、監控漂移、人工複判
機器人與 AMR（第 30 章）	未授權的指令、定位欺騙、通訊中斷	碰撞、人員受傷	獨立的安全功能、訊息驗證、失效保護
數位學生（第 19~21 章）	感測資料竄改、模型被修改	錯誤的決策與控制	物理一致性檢查、資料完整性、變更管理
機台雲與遠程運維（第 26、32 章）	帳號盜用、雲端服務被入侵	大量設備同時受影響	多因子驗證、單向資料、分區與監測

一個共同的原則是：AI 與數位系統可以提供建議與自動化，但安全相關的功能必須由獨立、可驗

證、不依賴 AI 的機制把關（第 30 章）；任何能改變實體世界的指令，都應經過驗證、授權與紀錄。

35.5.2 範例：以數位孿生檢查資料的完整性

數位孿生本身也能成為防護的工具：孿生的物理模型知道「在這樣的輸入下，系統應該處於什麼狀態」，因此可以發現與物理不一致的資料——不論它來自感測器故障，還是有人刻意竄改。下面的程式模擬一座加熱爐：從第 1,200 秒開始，溫度感測值被緩慢地拉低（實際爐溫正常）。感測值始終在正常的上下限之內；孿生則以加熱功率與環境溫度推算爐溫，對殘差做 CUSUM 檢定：

```
import numpy as np
# 數位孿生的資料完整性：若溫度感測值被竄改或故障而緩慢偏移，單看感測值的上下限不會警報。以孿生的物理模型（由加熱功率與環境溫度推算爐溫）檢查殘差，用 CUSUM 偵測
rng = np.random.default_rng(5)
T = 2000; dt = 1.0; a = 0.02
power = 50 + 10 * np.sin(np.arange(T) / 150) + rng.normal(0, 1, T); amb = 25 +
rng.normal(0, 0.3, T)
temp = np.zeros(T); temp[0] = amb[0] + 2.5 * power[0]
for k in range(1, T): temp[k] = temp[k-1] + a * (amb[k-1] + 2.5 * power[k-1] - temp[k-1])
* dt # 真實爐溫
meas = temp + rng.normal(0, 0.8, T); meas[1200:] -= np.linspace(0, 12, T - 1200) # 第
1200 秒起感測值緩慢被拉低（實際爐溫正常）
model = np.zeros(T); model[0] = meas[0]
for k in range(1, T): model[k] = model[k-1] + a * (amb[k-1] + 2.5 * power[k-1] - model[k-1])
* dt # 孿生：只用功率與環境溫度推算
print(f"感測值範圍 {meas.min():.0f}~{meas.max():.0f} °C；上下限警報（100~220 °C）觸發次數
{np.sum((meas < 100) | (meas > 220))}")
r = model - meas; mu, sd = r[:1000].mean(), r[:1000].std(); S = 0; alarm = None
for k in range(1000, T):
    S = max(0, S + (r[k] - mu) / sd - 0.5) # CUSUM：殘差持續偏高時累積
    if S > 8 and alarm is None: alarm = k
print(f"殘差 CUSUM 在第 {alarm} 秒警報（偏移從第 1200 秒開始，警報時感測值只偏低約 {12 *
(alarm - 1200) / (T - 1200):.1f} °C）")
```

執行結果：感測值始終在 117~176 °C 之間，上下限警報從未觸發；殘差 CUSUM 在第 1,255 秒發出警報，距偏移開始只有 55 秒，此時感測值只偏低約 0.8 °C。




圖 35-4 感測值、學生推算值與殘差 CUSUM

若控制系統依據被拉低的溫度自動加熱，實際的爐溫就會越來越高——這正是許多針對控制系統的攻擊試圖製造的情境。物理一致性檢查不需要知道攻擊的方式，只要資料不符合物理，就能及早發現。它也有限制：模型必須足夠準確，否則誤報太多；若攻擊者同時竄改多個相關的訊號，就需要更多獨立的量測來交叉檢查。這也說明了獨立的安全系統為什麼不應依賴同一套感測與網路。

35.5.3 資安是持續的工作

OT 資安不是一次性的專案，而是持續的循環：盤點資產與風險、設計區域與管道、建立監測與備份、演練事件應變、管理供應鏈與變更，再依新的威脅與技術調整。它也不是資安部門單獨的工作：生產、設備、資訊、採購、法務與設備商都需要參與。第 36 章將從 AI 治理的角度，進一步討論可信工業 AI 的管理體系。

案例

案例 35-1 教學情境：「我們的機台都沒有連網」

這是本章開頭的情境。盤點後發現雙網卡的工程站、設備商的遠端工具與未更新的 HMI，讓產線與辦公網路相通。工廠繪製資產與網路地圖、切分區域與管道、集中管理遠端存取；之後辦公室遭勒索軟體攻擊時，產線未受影響。

啟示：OT 資安始於看清楚資產與連線；切分與受控的通道是最有效的第一步。

案例 35-2 產業：新機台帶入的惡意程式

依公開報導，2018 年 8 月台灣一家晶圓代工廠在新機台安裝軟體時，因軟體帶有 WannaCry 勒索蠕蟲的變種且未經掃描就連上產線網路，導致多座晶圓廠的部分機台受到感染而停機，影響出貨（該變種未要求贖金）。事後業者強化了新機台進廠的檢查與隔離程序。

啟示：設備與軟體的供應鏈是 OT 的重要入口；進廠檢查與隔離不可省略。

案例 35-3 產業：IT 事件導致 OT 停線

依公開報導，2021 年 5 月美國最大的成品油管線業者的 IT 系統遭勒索軟體攻擊，雖然 OT 系統未被直接攻擊，公司仍主動停止管線運作約 6 天；報導指出，避免擴散與計費系統無法使用都是停運的原因。

啟示：IT 與 OT 的相依性讓 IT 事件也可能造成停產；營運區的備份與復原計畫同樣重要。

案例 35-4 產業：安全儀表系統成為目標

依公開資料，2017 年被揭露的 TRITON 惡意程式以某石化廠的安全儀表系統為目標，試圖修改其邏輯；事件因安全系統觸發停機而被發現。

啟示：安全系統必須獨立、受到最嚴格的保護，並監測其程式與設定的任何變更。

案例 35-5 台灣情境：中小企業的 OT 資安起步

一家台灣的金屬加工廠在客戶要求下開始處理 OT 資安。由於預算有限，他們從資產清單、更改預設密碼、停用不用的遠端工具、切分辦公與產線網路、離線備份 PLC 程式開始，再逐步導入網路監測。

啟示：中小企業可以從低成本、高效益的基本措施開始，逐步提升防護。

案例 35-6 教學情境：AI 模型從哪裡來？

學生從網路上下載一個「現成的瑕疵檢測模型」部署到學習工廠，後來發現模型檔的來源不明、格式可能在載入時執行程式碼，訓練資料也無從查證。團隊改為從可信的來源取得模型，記錄版本與雜湊值，在隔離環境中評測後才部署。

啟示：AI 模型與資料也是供應鏈的一部分，需要來源、完整性與評測的管理。

實作活動

活動 35-1 資產與網路地圖

為學習工廠或實驗室盤點所有連網的設備，繪製網路拓撲，標示 IT 與 OT 的界線、對外連線與可攜式媒體的使用，並找出三個最需要改善的地方。

活動 35-2 區域與管道設計

以 35.2 節的程式，為你的網路設計區域與管道，比較切分前後辦公電腦與外部連線對控制設備的可達性，並為每個管道說明用途與防護措施。

活動 35-3 OT 流量監測

在隔離的實驗環境中，以 Modbus 模擬器產生正常的輪詢流量，使用開源的網路監測工具建立白名單基準，並測試對新通訊對象與寫入指令的偵測。

活動 35-4 備份與還原演練

為一台 PLC 或機器人控制器建立程式與參數的備份，並實際演練一次還原，記錄所需的時間、工具與遇到的問題，撰寫復原手冊。

活動 35-5 SBOM 與弱點管理

以開源工具為一個軟體專案（例如你的 AI 推論服務）產生 SBOM，比對公開的弱點資料庫，依

風險排序並提出修補或補償措施。

活動 35-6 桌上演練

設計一個「勒索軟體加密 MES 與歷史資料庫」的桌上演練情境，分組扮演生產、設備、資訊、管理與設備商，討論偵測、圍堵、溝通、復原的決策與時序。

延伸閱讀

- IEC 62443 系列：工業自動化與控制系統的資安標準。
- NIST SP 800-82 Rev. 3 · Guide to Operational Technology (OT) Security (2023) 。
- MITRE ATT&CK for ICS：工業控制系統的攻擊戰術與技術知識庫（供防禦方建立偵測與演練）。
- CISA · Known Exploited Vulnerabilities Catalog：已知被利用的弱點清單。
- 數位發展部資通安全署：我國資通安全管理法規與指引。

表 35-4 本章思考地圖

本章概念	關鍵提問	後續延伸章節
IT 與 OT 差異	安全與可用性如何優先？誰負責 OT 資安？	第 36 章
區域與管道	每一條保留的路徑都是刻意、受控、被監測的嗎？	第 11、17 章
網路監測	監測能與變更管理結合嗎？	第 36 章
身分與遠端維護	設備商如何安全地連進來？	第 26、32 章
備份與應變	還原測試過嗎？PLC 程式有黃金映像嗎？	第 37、38 章
供應鏈安全	有 SBOM 嗎？模型與資料可驗證嗎？	第 28、33 章
新攻擊面	AI 與孿生是否有獨立的安全把關？	第 29、30、36 章

章末小結

- OT 以人身安全與可用性為優先，系統生命週期長、修補困難、協定多缺乏驗證，與 IT 的資安思維不同。歷史事件顯示 IT 與 OT 的界線、可攜式媒體、設備商與供應鏈常是入侵途徑，影響是生產與安全。
- IEC 62443 以區域與管道組織防護，並依風險訂定目標安全等級。範例中切分後辦公電腦無法到達現場設備，外部廠商只能經由受控的閘道到達，安全 PLC 完全隔離。零信任與白名單式的網路監測適合 OT 的規律流量，範例中三個異常事件都被偵測、正常流量無誤報，但需與變更管理結合。
- 身分管理、遠端維護、備援與事件應變是 OT 資安的日常。範例中只有同網段備份時平均停線約 121 小時，3-2-1 備份加不可變更快照與演練後約 12 小時；PLC 程式與設備參數的黃金映像同樣重要。我國《資通安全管理法》已於 2025 年修正。
- SBOM 讓弱點影響可以快速盤點，並依嚴重度、是否被利用與暴露程度排序修補；歐盟《網路韌性法》將逐步要求產品的資安與通報義務。AI 模型與資料也是供應鏈的一部分，需以來源、雜湊、簽章與評測管理。
- AI 代理、企業 AI、視覺模型、機器人、數位孿生與機台雲帶來新的攻擊面，安全功能必須獨立於 AI。數位孿生可以作為防護工具：範例中物理一致性檢查在感測值偏移約 0.8 °C 時就發出警報，而上下限警報從未觸發。

習題

一、選擇題

1. OT 資安通常最優先的目標是？（A）機密性 （B）人身安全與可用性 （C）不可否認性 （D）匿名性
2. 工業自動化與控制系統資安的國際標準系列是？（A）IEC 62443 （B）ISO 9001 （C）IEC 61131 （D）ISO 14001

3. 依安全需求把系統分區，只在區域間開放受控通道的概念是？(A) 區域與管道 (B) 負載平衡
(C) 虛擬化 (D) 容器化
4. 「永不信任、始終驗證」是哪一種架構的原則？(A) 零信任 (B) 扁平網路 (C) 單一登入
(D) 邊界防火牆
5. 列出軟體所含元件與版本的清單是？(A) SBOM (B) BOM (C) MRP (D) WBS
6. 可接受的最大資料損失時間稱為？(A) RPO (B) RTO (C) MTTR (D) MTBF
7. 三份資料、兩種媒體、一份離線或異地的備份原則是？(A) 3-2-1 (B) 1-2-3 (C) RAID 0
(D) 5S
8. 美國 NIST 的 OT 安全指南是？(A) SP 800-82 (B) SP 800-53 (C) FIPS 140 (D) SP
800-61
9. 在訓練資料中植入惡意樣本，使模型在特定條件下出錯，稱為？(A) 資料投毒 (B) 資料增強
(C) 資料清理 (D) 資料標註
10. 以物理模型檢查感測資料是否合理，可以偵測？(A) 感測器故障或資料竄改 (B) 網路頻寬不
足 (C) 硬碟容量不足 (D) 螢幕故障

二、簡答題

11. 比較 IT 與 OT 在資安目標、系統生命週期與修補上的差異。
12. 為什麼 OT 系統難以像 IT 一樣定期修補？可以採取哪些補償措施？
13. 說明區域與管道的設計原則，以及保留路徑應具備的條件。
14. 為什麼白名單式的網路監測適合 OT？它的限制是什麼？
15. 安全的遠端維護應包含哪些措施？
16. 為什麼備份需要定期測試還原？OT 還需要備份哪些項目？
17. SBOM 如何幫助弱點管理？修補的優先序應考慮哪些因素？
18. AI 代理與數位孿生帶來哪些新的攻擊面？共同的防護原則是什麼？

三、計算題

19. 某工廠有 120 台設備，其中 30 台對外暴露。若對外暴露的設備每年被攻擊成功的機率為 5%，其餘為 0.5%，一年預期被攻擊成功的設備數為多少？
20. 停線每小時損失 80 萬元，平均停線時間從 121 小時降到 12 小時，每次事件減少多少損失？
21. 若每年發生勒索事件的機率為 15%，接上題，每年的預期損失減少多少？
22. 某弱點 CVSS 7.5、未被利用、對外暴露；另一個 CVSS 9.8、已知被利用、未暴露。以「CVSS + 被利用 3 + 暴露 2」計算優先序，哪一個先處理？
23. 一份每日備份在 0 時進行，攻擊發生在 15 時，若只能從當天的備份還原，資料損失多少小時？
24. 網路監測基準一天有約 17.3 萬筆通訊，若每筆平均 120 位元組，一天約多少 MB？
25. 扁平網路中 13 台設備兩兩互通（有向），共有多少條連線？切分後只保留 15 條，減少多少百分比？
26. 某資產的風險 = 可能性（1~5）× 影響（1~5）。HMI 為 4×3 ，安全 PLC 為 2×5 ，MES 為 3×4 ，請排序。

四、申論與設計題

27. 為一座中型工廠設計 OT 資安計畫：說明資產盤點、區域與管道、遠端存取、監測、備份、事件應變與人員訓練。
28. 評論以下說法：「我們的設備沒有連上網際網路，所以不需要 OT 資安。」
29. 為一個部署在產線的 AI 視覺檢測系統設計供應鏈安全與完整性的管理流程，從模型與資料取得、驗證、部署到監控。

五、是非題

30. OT 系統可以像辦公電腦一樣每月自動更新。
31. 區域與管道的目的是切斷所有的連線。
32. 白名單監測可能對合法但不常見的操作發出警報。

- 33. 備份只要有做，不需要測試還原。
- 34. 從網路下載的預訓練模型一定是安全的。
- 35. 安全相關的功能應獨立於 AI 系統。

六、進階挑戰題

- 36. 在隔離的實驗環境中建立一個小型 ICS (PLC 模擬器、HMI、歷史資料庫)，依 IEC 62443 設計區域與管道，部署開源的網路監測工具，並以 MITRE ATT&CK for ICS 設計防禦演練情境。
- 37. 為一個 AI 推論服務建立完整的軟體與模型供應鏈管理：自動產生 SBOM、比對弱點資料庫、驗證模型的雜湊與簽章，並整合到持續部署流程中。
- 38. 以數位孿生的殘差檢查為基礎，設計一個能同時監測多個感測器並區分「感測器故障」與「製程異常」的方法，並以模擬資料評估偵測率與誤報率。

七、補充題

- 39. 列出表 35-2 中 IT 與 OT 差異的七個面向。
- 40. 列出事件應變的六個階段。

提示與參考解答

- 1. B。
- 2. A。
- 3. A。
- 4. A。
- 5. A。
- 6. A。
- 7. A。
- 8. A。
- 9. A。

10. A。

11. 參考：IT 以機密性為首，OT 以人身安全與可用性為首；IT 系統 3~5 年更新，OT 常用 15~30 年；IT 可定期自動修補，OT 需停機與驗證，常延後或無法修補。

12. 參考：修補需停機、需設備商驗證、可能影響即時性或相容性，部分設備已停止支援。補償措施包括加強隔離、限制存取、白名單、監測與定期備份。

13. 參考：依安全需求劃分區域，區域間只開放必要、受控的管道；保留的路徑應是刻意的、受控的（驗證、授權、限定範圍與時間）、被監測與記錄的。

14. 參考：OT 流量高度規律，正常的通訊組合有限，偏離容易被發現，誤報少。限制是合法但不常見的操作也會觸發警報，需與變更管理結合；也可能遺漏利用既有合法通道的攻擊。

15. 參考：集中的遠端存取閘道、多因子驗證、事先申請與限定時間範圍、全程錄影、必要時人員陪同、結束後自動中斷、禁止自行安裝遠端工具。

16. 參考：未測試的備份可能無法還原或缺少必要的軟體與授權。OT 還需要備份 PLC 與機器人程式、HMI 畫面、設備參數與網路設定的黃金映像。

17. 參考：SBOM 讓組織快速知道哪些設備受某個弱點影響。優先序考慮嚴重度、是否已知被利用、是否對外暴露、資產的重要性與可用的補償措施。

18. 參考：提示注入、工具濫用、資料與模型污染、對抗樣本、定位欺騙、感測資料竄改、雲端帳號盜用等。共同原則是最小權限、驗證與授權、紀錄，以及安全功能獨立於 AI。

19. $30 \times 5\% + 90 \times 0.5\% = 1.5 + 0.45 = 1.95$ 台。

20. $(121 - 12) \times 80 = 8,720$ 萬元。

21. $8,720 \times 15\% = 1,308$ 萬元。

22. 前者 $7.5 + 0 + 2 = 9.5$ ；後者 $9.8 + 3 + 0 = 12.8$ ，後者先處理。

23. 15 小時。

24. $173,000 \times 120 \approx 20.8$ MB。

25. $13 \times 12 = 156$ 條； $(156 - 15) \div 156 \approx 90.4\%$ 。

26. HMI 12、MES 12、安全 PLC 10；HMI 與 MES 並列最高，但安全 PLC 的影響最大，應同時考慮最高影響的資產。
27. 參考：盤點資產與連線；依 Purdue 模型與 IEC 62443 劃分區域與管道；集中遠端存取閘道；部署被動式網路監測並與變更管理結合；3-2-1 備份與黃金映像；建立事件應變計畫與桌上演練；對人員與設備商進行訓練。
28. 參考：不同意。可攜式媒體、設備商的遠端連線、雙網卡的電腦、與 MES 的連接，以及新設備帶入的軟體，都可能成為入侵途徑；需盤點並管理所有連線與媒介。
29. 參考：只從可信來源取得模型與資料，記錄來源、版本與雜湊；以數位簽章驗證；使用安全的模型格式；在隔離環境中評測；部署時比對簽署清單；上線後監控漂移與異常；建立變更與回復流程。
30. 否。
31. 否。
32. 是。
33. 否。
34. 否。
35. 是。
36. 提示：所有實驗必須在與生產網路完全隔離的環境中進行；演練以偵測與應變為目的。
37. 提示：在持續部署流程中加入 SBOM 產生、弱點比對與簽章驗證的關卡，未通過即停止部署。
38. 提示：以多個獨立的物理關係交叉檢查，單一感測器的殘差異常較可能是感測器問題，多個相關殘差同時異常較可能是製程異常。
39. 優先目標、系統生命週期、更新與修補、即時性要求、通訊協定、異常的後果、管理者。
40. 準備、偵測與分析、圍堵、根除、復原、事後檢討。

第 36 章

AI 治理與可信工業 AI

編著 李世淵 (機器人叫獸) | 助教 李天宇、李宇晴

本章重點

- AI 原則與子群評測
- NIST AI RMF、ISO / IEC 42001 與風險登錄
- 模型卡、資料卡與紅隊測試
- 設計責任、智慧財產與法規時程
- 人類最終責任、變更管理與持續稽核

叫獸開講：誰簽名，誰負責

有一次我參加一家企業的 AI 專案驗收。專案團隊展示了一個預測產品不良的模型，整體正確率將近九成，主管們很滿意，準備簽字上線。品保經理翻了翻報告，問了一個問題：「這個正確率，是三條產線加起來算的吧？C 線的設備比較舊，它在 C 線的表現呢？」

團隊愣了一下，回去分線計算：A、B 兩線都很好，C 線的正確率卻明顯偏低，模型的「信心」也不太可靠——說有九成把握的時候，實際上只對七成多。原因很簡單：C 線的訓練資料只有一百多筆。整體的數字把這個問題藏住了。

品保經理接著問：「如果上線後漏檢了，客訴回來，誰負責？是寫程式的工程師、提供資料的產線，還是簽字的主管？模型以後誰來更新？新產品導入時要不要重新驗證？」會議室安靜了很久。最後的決定是：A、B 線先上線，C 線維持人工全檢並補充資料；模型要有一份說明用途與限制的「模型卡」，指定一位負責人；任何更新都要經過評測與核准；每半年重新驗證一次。

這就是 AI 治理：它不是阻擋 AI 的官僚流程，而是讓 AI 被安全、可靠、負責任地使用的制度。這一章，我們從可信 AI 的原則談起；介紹 NIST AI 風險管理框架與 ISO / IEC 42001 管理系統；說明模型卡、資料卡、紅隊測試與風險登錄；討論設計責任、智慧財產與法規遵循；最後談人類的最終責任、變更管理與持續稽核。

（說明：本節情境由作者綜合企業輔導經驗改寫，人物與細節已調整。）

學習目標

讀完本章後，你應該能夠：

1. 說明可信 AI 的主要原則：安全、可靠、公平、透明、隱私與問責，並以分群評測發現整體指標隱藏的問題。
2. 說明 NIST AI RMF 與 ISO / IEC 42001 的架構，並建立 AI 風險登錄。
3. 撰寫模型卡與資料卡，說明模型的用途、限制與資料來源。
4. 設計紅隊測試與驗收標準，評估模型在壓力情境與分布外資料下的表現。

5. 說明 AI 相關的設計責任、智慧財產與主要法規。

6. 設計人類最終責任、變更管理與持續稽核的機制。

核心概念

表 36-1 本章核心名詞中英對照

中文名詞	英文	一句話說明
可信 AI	Trustworthy AI	安全、可靠、公平、透明、尊重隱私並可問責的 AI
AI 治理	AI Governance	管理 AI 開發、部署與使用的組織、制度與流程
AI 風險管理框架	NIST AI RMF	以治理、對應、衡量、管理四項功能管理 AI 風險
AI 管理系統	ISO/IEC 42001	組織建立、實施與持續改善 AI 管理的標準
模型卡	Model Card	說明模型用途、效能、限制與倫理考量的文件
資料卡	Datasheet / Data Card	說明資料集來源、組成、蒐集方式與限制的文件
紅隊測試	Red Teaming	以對抗的角度刻意尋找系統的弱點與失效模式
風險登錄	Risk Register	記錄風險、評估、控制與負責人的清單
校準	Calibration	模型的信心與實際正確率的一致程度
子群評測	Subgroup Evaluation	分別評估模型在不同群體或條件下的表現
分布外偵測	Out-of-Distribution Detection	辨識與訓練資料分布不同的輸入
變更管理	Change Management	管控系統變更的申請、評估、核准與紀錄
持續稽核	Continuous Audit	持續檢查實際運作是否符合政策
人類監督	Human Oversight	人能理解、監督並在必要時介入 AI 的運作

36.1 安全、可靠、公平、透明、隱私與問責

36.1.1 可信 AI 的原則

各國的 AI 原則與法規用詞不盡相同，但核心大致一致。對工業 AI 而言，這些原則有具體的意

義：

表 36-2 可信 AI 的原則在工業中的意義

原則	一般意義	工業中的具體問題
安全	不造成傷害	AI 的錯誤會不會導致設備損壞、產品缺陷或人員受傷？安全功能是否獨立？
可靠與穩健	在預期條件下穩定運作	換線、換料、設備老化時表現如何？有沒有漂移監控？
公平	不對特定群體不利	在不同產線、班別、供應商、操作員之間的表現是否一致？
透明與可解釋	讓人理解 AI 的運作	使用者知道模型的用途、限制與信心嗎？（第 31 章）
隱私與資料保護	保護個人與機密資料	影像、語音、操作紀錄與營業秘密如何保護？
問責	有人為結果負責	誰核准、誰負責更新、出錯時如何追溯？
資安	抵禦攻擊與濫用	模型與資料的完整性、代理的權限（第 35 章）

在製造業中，「公平」常常不是關於人，而是關於條件：一個在大多數條件下表現良好的模型，可能在少數的產線、產品或料件上表現很差。這些少數條件，往往正是風險最高的地方。

36.1.2 範例：整體指標隱藏的問題

下面的程式訓練一個焊點不良的預測模型，資料來自 A、B、C 三條產線；C 線的設備較舊、製程條件的分布不同，而且訓練資料只有 150 件。分別評估各線的正确率、不良召回率與校準誤差（模型的信心與實際正确率的差距）：

```
import numpy as np
from sklearn.linear_model import LogisticRegression
# 可靠與公平：一個預測焊點不良的模型，整體正確率很高，但在不同產線（設備較舊的 C 線）與不同供應商的料件上表現不一，信心的校準也不同
rng = np.random.default_rng(1)
def data(n, line, shift):
    X = rng.normal(0, 1, (n, 5)); X[:, 0] += shift # C 線的設備較舊：製程條件的分布偏移
    y = (1.5 * X[:, 0] - X[:, 1] + 0.8 * X[:, 2] * (2.5 if line == "C" else 1) - (1.0 * X[:, 3] if line == "C" else 0) + rng.normal(0, 0.8, n) > 1.2).astype(int)
    return X, y
parts = {"A": data(4000, "A", 0), "B": data(4000, "B", 0.2), "C": data(800, "C", 0.9)}
ntr = {"A": 3000, "B": 3000, "C": 150} # C 線的訓練資料很少
Xtr = np.vstack([parts[k][0][:ntr[k]] for k in parts]); ytr =
np.concatenate([parts[k][1][:ntr[k]] for k in parts])
m = LogisticRegression().fit(Xtr, ytr)
def ece(p, y, bins=10): # 預期校準誤差：信心與實際
    正確率的差距
```

```

idx = np.minimum((p * bins).astype(int), bins - 1); e = 0
for b in range(bins):
    k = idx == b
    if k.any(): e += k.mean() * abs(p[k].mean() - y[k].mean())
return e
allp, ally = [], []
for k, (X, y) in parts.items():
    Xt, yt = X[ntr[k]:], y[ntr[k]:]; p = m.predict_proba(Xt)[:, 1]; pred = p > 0.5
    rec = np.mean(pred[yt == 1]); print(f"{k} 線：測試 {len(yt)} 件，不良率
{yt.mean():.0%}，正確率 {np.mean(pred == yt):.1%}，不良召回率 {rec:.1%}，校準誤差 {ece(p,
yt):.3f}")
    allp.append(p); ally.append(yt)
p, y = np.concatenate(allp), np.concatenate(ally); print(f"全部：正確率 {np.mean((p > 0.5)
== y):.1%}，不良召回率 {np.mean((p > 0.5)[y == 1]):.1%}，校準誤差 {ece(p, y):.3f}")

```

執行結果：A 線的正确率約 88.2%、B 線約 90.5%，校準誤差都約 0.03；C 線的正确率只有約 78.3%，校準誤差約 0.097，是其他兩線的三倍多。但三線合計時，正確率約 86.6%、校準誤差約 0.029，看起來一切正常。




圖 36-1 分產線的正确率與校準：整體指標隱藏了 C 線的問題

這正是本章開頭的情境。子群評測應該成為驗收的標準程序：依產線、產品、料件來源、班別等條件分別評估，並為每個子群設定可接受的門檻。對於未達標準的子群，可以限制模型的適用範圍（例如 C 線維持人工檢驗）、補充資料、或在介面上明確標示（第 31 章的信任校準）。

36.2 NIST AI RMF 與 ISO / IEC 42001

36.2.1 NIST AI 風險管理框架

美國國家標準與技術研究院（NIST）在 2023 年 1 月發布 AI 風險管理框架（AI RMF 1.0），以四項功能組織 AI 風險管理：治理（建立文化、政策、角色與責任）、對應（了解 AI 系統的情境、用途與可能的影響）、衡量（以量化與質性的方法評估風險）、管理（依優先序處理風險並持續監

控)。2024 年 7 月，NIST 另發布了針對生成式 AI 的剖繪文件 (NIST AI 600-1，Generative AI Profile)。AI RMF 是自願性的框架，不是法規，但被廣泛採用為企業 AI 治理的參考。

36.2.2 ISO / IEC 42001

ISO / IEC 42001 於 2023 年 12 月發布，是第一個 AI 管理系統的國際標準。它採用與 ISO 9001、ISO / IEC 27001 相同的管理系統架構 (規劃、實施、檢查、改善)，要求組織建立 AI 政策、評估 AI 風險與對社會的影響、管理 AI 系統的生命週期、管理第三方與供應商，並持續改善；組織可以申請第三方驗證。已經導入 ISO 9001 品質管理或 ISO / IEC 27001 資訊安全管理的製造業者，可以把 AI 管理整合到既有的體系中 (第 25 章的 QMS)。

表 36-3 AI 治理框架的比較

框架	性質	核心內容	適用情境
NIST AI RMF	自願性框架	治理、對應、衡量、管理	建立 AI 風險管理的方法
ISO / IEC 42001	可驗證的管理系統標準	AI 政策、風險與影響評估、生命週期、持續改善	需要對外證明 AI 管理能力
ISO / IEC 23894	指引	AI 風險管理的指引	搭配 ISO 31000 風險管理
歐盟《人工智慧法》	法規	依風險分級的義務，高風險系統的要求	在歐盟市場提供或使用 AI
我國《人工智慧基本法》	基本法	人類自主、透明、公平、問責等原則與推動機制	國內 AI 發展與治理的基礎

36.2.3 範例：AI 風險登錄

風險登錄是把治理落實到日常的工具：列出每一項風險、評估可能性與影響、指定控制措施與負責人，並追蹤剩餘風險。下面的程式為一個 AI 視覺檢測系統建立風險登錄，依固有風險排序，並計算實施控制後的剩餘風險：

AI 風險登錄：依 NIST AI RMF 的「治理、對應、衡量、管理」，為一個 AI 視覺檢測系統登錄風險，計算固有風險與實施控制後的剩餘風險，並排出處理順序
 RISKS = [# 風險、可能性 (1~5)、影響 (1~5)、控制措施、控制後可能性、控制後影響、RMF 功能

```

("新產品上線後漏檢率上升(資料漂移)", 4, 4, "漂移監控、新產品重新驗證", 2, 4, "衡量/管理"),
("低信心案例被作業員直接放行(過度依賴)", 4, 3, "信心顯示、低信心強制複判", 2, 3, "對應/管理"),
("某條產線的表現明顯較差(子群差異)", 3, 3, "分產線評測、增加該線資料", 2, 2, "衡量"),
("模型檔被替換或竄改", 2, 5, "雜湊與簽章驗證、部署關卡", 1, 5, "管理"),
("影像中拍到人員, 涉及隱私", 3, 2, "遮蔽、只保存缺陷區域、存取控制", 1, 2, "治理"),
("無人負責模型的更新與退役", 3, 4, "指定模型負責人、模型登錄與變更流程", 1, 3, "治理"),
("供應商的預訓練模型授權不清", 2, 3, "授權審查、模型卡記錄來源", 1, 2, "治理")]
def level(s): return "高" if s >= 12 else ("中" if s >= 6 else "低")
rows = sorted(RISKS, key=lambda r: -r[1] * r[2])
for name, l, i, ct1, l2, i2, fn in rows:
    print(f"{name} | 固有 {l * i} ({level(l * i)}) → 剩餘 {l2 * i2} ({level(l2 * i2)}) | {ct1} | {fn}")
inh = sum(r[1] * r[2] for r in RISKS); res = sum(r[4] * r[5] for r in RISKS)
print(f"風險分數合計: 固有 {inh} → 剩餘 {res} (降低 {1 - res / inh:.0%}); 剩餘風險仍為「中」以上的項目 {sum(r[4] * r[5] >= 6 for r in RISKS)} 項, 需管理層接受並定期檢視")

```

執行結果：固有風險最高的是「新產品上線後漏檢率上升」（16·高），其次是「低信心案例被直接放行」與「無人負責模型的更新與退役」（各12·高）。實施控制後，風險分數合計從71降到30，約降低58%；但仍有2項剩餘風險為「中」——資料漂移與過度依賴——需要管理層明確接受並定期檢視。




圖 36-2 AI 風險的固有風險與剩餘風險

風險登錄的價值不在分數本身，而在於讓每一項風險「有人負責、有控制、有追蹤」。值得注意的是，固有風險很高的「無人負責」，控制措施並不是技術，而是組織——指定負責人、建立模型登錄與變更流程。許多 AI 的失敗，根源是治理的空白，而不是演算法。

36.3 模型卡、資料卡、紅隊測試與風險登錄

36.3.1 模型卡與資料卡

2019 年 Mitchell 等人提出「模型卡」，主張每個發布的模型都應附上一份簡短的文件，說明預期的用途與不適用的情境、評測的方法與結果（包括不同子群的表現）、限制與倫理考量。Gebru 等人提出的「資料集說明書」（datasheets for datasets）則說明資料集的動機、組成、蒐集方式、前處理、使用建議與維護。在工業中，這兩份文件是模型登錄（第 23 章的 MLOps）的一部分，讓使用者、稽核者與未來的維護者知道這個模型能做什麼、不能做什麼。

下面的程式從模型登錄的中繼資料與 36.1 節的評測結果，自動產生模型卡，並以資料的統計產生資料卡的摘要：

```
import json, numpy as np
# 模型卡與資料卡：從模型登錄的中繼資料與評測結果，自動產生模型卡；並從資料統計產生資料卡的摘要，讓使用者知道模型的用途、限制與資料來源
rng = np.random.default_rng(3)
meta = {"name": "焊點不良判定模型", "version": "2.3.0", "owner": "品保部 AI 小組", "date": "2026-09-15",
        "intended_use": "SMT 產線 AOI 可疑焊點的複判輔助；最終判定由作業員確認", "not_for": ["安全相關零件的唯一判定依據", "未經驗證的新產品"],
        "training_data": "2025-10~2026-08, A、B、C 三線，共 6,150 件（C 線僅 150 件）",
        "base_model": "內部訓練，無外部預訓練權重"}
evals = {"A 線": (0.882, 0.756, 0.030), "B 線": (0.905, 0.823, 0.027), "C 線": (0.783, 0.791, 0.097)} # 正確率、不良召回率、校準誤差（取自 36.1 節）
lots = rng.choice(["供應商甲", "供應商乙", "供應商丙"], 6150, p=[0.6, 0.35, 0.05]); missing = {"潤濕角": 0.012, "空洞率": 0.048}
def model_card(meta, evals, threshold=0.85):
    lines = [f"# 模型卡：{meta['name']} v{meta['version']}", f"負責人：{meta['owner']} | 發布日期：{meta['date']}",
             f"預期用途：{meta['intended_use']}", "不適用：" + " ".join(meta["not_for"]),
             f"訓練資料：{meta['training_data']}", f"基礎模型：{meta['base_model']}", "評測結果："]
    for k, (acc, rec, e) in evals.items():
        flag = "" if acc >= threshold and e < 0.05 else "（未達標準：正確率或校準不足，需人工全檢或補充資料）"
        lines.append(f"  {k}：正確率 {acc:.1%}、不良召回率 {rec:.1%}、校準誤差 {e:.3f}{flag}")
    return "\n".join(lines)
def data_card():
    share = {k: float(np.mean(lots == k)) for k in ["供應商甲", "供應商乙", "供應商丙"]}
    return f"資料卡摘要：料件來源 " + " ".join(f"{k} {v:.0%}" for k, v in share.items()) +
    "；缺值率 " + " ".join(f"{k} {v:.1%}" for k, v in missing.items()) + "；供應商丙的樣本偏少，模型對其料件的表現未經充分驗證"
print(model_card(meta, evals)); print(data_card())
```

執行結果：模型卡列出了負責人、預期用途（AOI 可疑焊點的複判輔助，最終由作業員確認）、不適用的情境、訓練資料與各產線的評測結果，並自動標示 C 線「未達標準，需人工全檢或補充資

料」；資料卡指出供應商丙的樣本只佔約 5%，模型對其料件的表現未經充分驗證。

自動產生的好處是：模型卡與實際的評測結果保持一致，不會因為人工撰寫而遺漏不利的數字。

模型卡也應隨著版本更新，並與第 28 章的評測題庫、第 35 章的模型雜湊與簽章連結。

36.3.2 紅隊測試與驗收

紅隊測試以「找出問題」為目標，刻意以各種壓力情境測試 AI 系統：感測雜訊、量測偏移、缺值、分布外的輸入、對抗樣本，以及對語言模型與代理的提示注入（第 29 章）。每一項測試都應有事先訂定的驗收標準。下面的程式以四個壓力情境測試 36.1 節的模型，驗收標準為正確率下降不超過 5 個百分點；並測試以馬氏距離偵測分布外的新產品：

```
import numpy as np
from sklearn.linear_model import LogisticRegression
# 紅隊測試與驗收：以一組「壓力情境」測試 36.1 節的模型—感測雜訊加大、量測偏移、缺值以中位數補
# 值、分布外的新產品。每一項都有驗收標準，未通過者不得上線或需加上防護
# 延續 36.1 節的程式（資料、模型 m 與訓練資料 Xtr）
Xt = np.vstack([parts[k][0][ntr[k]:] for k in "AB"]); yt =
np.concatenate([parts[k][1][ntr[k]:] for k in "AB"])
base = np.mean((m.predict_proba(Xt)[: , 1] > 0.5) == yt)
def acc(X, y=yt): return np.mean((m.predict_proba(X)[: , 1] > 0.5) == y)
tests = {
    "感測雜訊加倍": lambda: acc(Xt + rng.normal(0, 0.5, Xt.shape)),
    "錫量量測偏移 +0.5": lambda: acc(Xt + np.r_[0.5, 0, 0, 0, 0]),
    "空洞率缺值 (10%，以中位數補值)": lambda: acc(np.where((rng.random(Xt.shape) < 0.1) &
(np.arange(5) == 2), np.median(Xt[: , 2]), Xt)),
    "新產品 (分布外)": lambda: acc(*data(1000, "C", 2.0))}
def ood_score(X): mu, cov = Xtr.mean(0), np.cov(Xtr.T); d = X - mu; return
np.sqrt(np.einsum("ij,jk,ik->i", d, np.linalg.inv(cov), d))
print(f"基準正確率 (A、B 線) : {base:.1%}; 驗收標準: 每項下降不超過 5 個百分點")
for name, f in tests.items():
    a = f(); print(f"{name}: {a:.1%} (下降 {100 * (base - a):.1f} 點) → {'通過' if base - a
<= 0.05 else '未通過'}")
Xn, yn = data(1000, "C", 2.0); s_in, s_new = ood_score(Xt), ood_score(Xn); thr =
np.percentile(s_in, 99)
print(f"分布外偵測 (馬氏距離, 門檻為訓練分布的 99 百分位): 新產品被標記 {np.mean(s_new >
thr):.0%}, 正常樣本誤標 {np.mean(s_in > thr):.0%}")
```

執行結果：基準正確率約 89.3%。錫量量測偏移 +0.5（下降約 3.7 點）與空洞率缺值（下降約 1.0 點）通過；感測雜訊加倍（下降約 6.7 點）與新產品（下降約 5.1 點）未通過。分布外偵測只標記了約 10% 的新產品樣本，正常樣本的誤標約 1%。



圖 36-3 壓力情境下的正確率與驗收標準

未通過的項目不代表模型不能用，而是要求加上對應的防護：感測雜訊加倍代表模型依賴量測品質，因此要監控量測系統（第 25 章的 MSA）；新產品的表現下降，代表新產品導入時必須重新驗證。分布外偵測的結果也很有啟發：單純以輸入的統計距離，只抓到一成的新產品樣本——與其依賴模型自己察覺「這是新東西」，不如直接用製程的資訊（新的料號、新的配方）觸發重新驗證。工程知識與流程，往往比演算法更可靠。

36.4 設計責任、智慧財產與法規遵循

36.4.1 設計與產品責任

當 AI 成為產品或製程的一部分，責任的問題就變得具體：AI 輔助設計的零件失效，責任在設計工程師、AI 工具的供應商，還是核准的主管？AI 檢測漏掉了缺陷，客戶的損失由誰承擔？原則上，使用 AI 不會轉移專業的責任：工程師仍須依專業標準審查與驗證 AI 的產出（第 14 章的生成式設計、第 21 章的模擬與驗證），組織仍須為其產品負責。法規也在調整：歐盟新的《產品責任指令》（Directive (EU) 2024/2853，2024 年 12 月生效、適用於 2026 年 12 月 9 日以後投放市場的產品）明確把軟體——包括 AI 系統——納入「產品」的範圍，製造商對有瑕疵的軟體與未提供必要的安全更新都可能承擔責任。

36.4.2 智慧財產

AI 帶來幾類智慧財產的問題。第一，訓練資料的權利：使用第三方的資料、圖面、文件訓練模

型，是否有授權？客戶提供的資料能否用於訓練其他客戶的模型（第 32 章的機台雲）？第二，模型與工具的授權：開源模型與套件的授權條款可能限制商業使用或要求公開修改。第三，AI 產出的權利：許多國家的實務認為，完全由 AI 自動生成、沒有人類創作貢獻的內容，難以取得著作權；專利的發明人原則上也必須是自然人，但人類運用 AI 作為工具完成的發明，仍可依一般要件申請專利。第四，營業秘密：把製程參數、配方或客戶資料輸入外部的 AI 服務，可能造成營業秘密的外洩（第 28 章的部署選擇）。實務上，企業應建立 AI 使用的政策：哪些資料可以輸入哪些服務、模型與資料的授權如何審查、AI 產出如何標示與審查。

36.4.3 法規遵循

表 36-4 與工業 AI 相關的主要法規與時程（截至本書撰寫時）

法規	重點	對製造業的意義
歐盟《人工智慧法》	依風險分級；禁止的應用自 2025 年 2 月適用、通用 AI 模型的義務自 2025 年 8 月適用；透明度義務自 2026 年 8 月適用；高風險系統的義務經 2026 年 7 月生效的修正（Regulation (EU) 2026/1744）延後，獨立的高風險系統（附件 III）自 2027 年 12 月、嵌入受規範產品者（附件 I）自 2028 年 8 月起適用	安全元件、機械、醫材中的 AI 屬高風險類別；出口歐盟的產品需提前準備
歐盟《產品責任指令》	軟體與 AI 納入產品；2026 年 12 月起適用	軟體瑕疵與安全更新的責任
歐盟《機械法規》	取代機械指令 2006/42/EC，2027 年 1 月 20 日起適用；納入具自主行為與 AI 的安全元件	機器人與自動化設備的符合性評估（第 30 章）
歐盟《網路韌性法》	具數位元素產品的資安要求（第 35 章）	設備與軟體的弱點管理與通報

法規	重點	對製造業的意義
我國《人工智慧基本法》	2025 年 12 月 23 日三讀通過、2026 年 1 月 14 日公布施行，中央主管機關為國科會；揭示人類自主、隱私與資料治理、資安與安全、透明與可解釋、公平與不歧視、問責等原則	各主管機關將據以訂定相關規範
我國《個人資料保護法》	個人資料的蒐集、處理與利用	影像、語音、操作紀錄中的個人資料（第 31 章）

法規變動很快，以上時程以撰寫時的公開資訊為準，實際適用應以最新的官方公告為依據。對於製造業者，最務實的做法是：建立 AI 系統的清單與風險分級，依產品的市場確認適用的法規，並把法規要求整合到既有的品質、安全與資安管理體系中，而不是另起爐灶。

36.5 人類最終責任、變更管理與持續稽核

36.5.1 人類最終責任

本書反覆強調：AI 提供建議與自動化，人負最終的責任。這句話要落實，需要幾個條件：每一個 AI 系統都有明確的負責人；人有足夠的資訊、時間與能力做出判斷（第 31 章的信任校準與 AI Copilot）；AI 的權限有清楚的邊界與核准機制（第 29 章）；安全相關的功能獨立於 AI（第 30、35 章）；而且組織的文化允許人質疑與推翻 AI 的建議。若系統的設計讓人來不及判斷，或在績效壓力下只能按下同意，就不能把責任完全推給最後按下按鈕的人。

36.5.2 變更管理

AI 系統會不斷變化：重新訓練、更換模型、調整門檻、修改提示、更新知識庫、升級套件。每一項變更都可能改變行為。工業 AI 的變更管理可以沿用製造業既有的工程變更流程（第 17、20 章）：變更申請、影響評估、評測與驗證、核准、部署、上線後監控，以及必要時的回復。模型登錄記錄每一個版本的模型卡、評測結果、核准紀錄與部署位置，是變更管理的基礎。

36.5.3 範例：持續稽核

制度的關鍵在於「實際上有沒有照做」。持續稽核以程式自動比對實際的運作紀錄與政策，及早發現缺失。下面的程式稽核 5 個模型部署：每次部署必須有核准、有評測報告、驗證未逾期（180 天），核准人須在職；漂移警報後須在 14 天內重新驗證：

```
from datetime import date
# 變更管理與持續稽核：比對模型部署紀錄與政策——每次部署必須有核准、有評測報告、驗證未逾期（180
# 天）、負責人在職；漂移警報後須在 14 天內重新驗證
POLICY = {"valid_days": 180, "revalidate_days": 14}
staff = {"王工程師", "林課長", "陳經理"} # 目前在職、具核准權限的人員
deploys = [ # 模型、版本、部署日、核准人、評測報告、上次驗證日、漂移警報日（無則 None）
    ("焊點判定", "2.3.0", date(2026, 9, 15), "林課長", "EVAL-2309", date(2026, 9, 10),
None),
    ("刀具壽命", "1.4.2", date(2026, 8, 1), "陳經理", "EVAL-1402", date(2026, 1, 20),
None),
    ("能源排程代理", "0.9.1", date(2026, 9, 28), None, None, date(2026, 9, 25), None),
    ("外觀刮傷", "3.1.0", date(2026, 6, 3), "張主任", "EVAL-3100", date(2026, 6, 1),
date(2026, 9, 1)),
    ("良率預測", "2.0.0", date(2026, 7, 20), "王工程師", "EVAL-2000", date(2026, 7, 18),
date(2026, 9, 25))]
def audit(today=date(2026, 10, 7)):
    findings = []
    for name, v, d, appr, ev, val, drift in deploys:
        if appr is None: findings.append((name, v, "未經核准即部署"))
        elif appr not in staff: findings.append((name, v, f"核准人「{appr}」已不在職或無權
限，需重新指定負責人"))
        if ev is None: findings.append((name, v, "缺少評測報告"))
        if (today - val).days > POLICY["valid_days"]: findings.append((name, v, f"驗證已逾
期 {(today - val).days - POLICY['valid_days']} 天"))
        if drift and (today - drift).days > POLICY["revalidate_days"] and val < drift:
findings.append((name, v, f"漂移警報後 {(today - drift).days} 天仍未重新驗證"))
    return findings
f = audit(); print(f"稽核 {len(deploys)} 個模型部署，發現 {len(f)} 項缺失：")
for name, v, msg in f: print(f"  {name} v{v}: {msg}")
```

執行結果：發現 5 項缺失：刀具壽命模型的驗證已逾期 80 天；能源排程代理未經核准即部署、也缺少評測報告；外觀刮傷模型的核准人已不在職，且漂移警報後 36 天仍未重新驗證。焊點判定與良率預測模型符合政策（後者的漂移警報才 12 天，仍在期限內）。




圖 36-4 AI 治理的循環：政策、風險、評測、核准、監控與稽核

這些缺失都很常見：人員異動後沒有人接手、急著上線而跳過流程、警報響了卻沒有人處理。持續稽核把它們變成可以追蹤的待辦事項。它也提醒我們：AI 治理不是一份文件，而是一個持續運作的循環——政策、風險評估、評測與核准、部署與監控、稽核與改善——與第 25 章的品質管理、第 35 章的資安管理一脈相承。

案例

案例 36-1 教學情境：誰簽名，誰負責

這是本章開頭的情境。整體正確率將近九成的模型，在設備較舊、資料較少的 C 線表現明顯較差。驗收時改為分線評測，A、B 線先上線、C 線維持人工全檢，並建立模型卡、指定負責人與定期重新驗證。

啟示：整體指標可能隱藏少數條件下的風險；治理讓責任與限制變得明確。

案例 36-2 產業：以既有管理系統整合 AI 治理

依公開資料，部分製造業者在 ISO 9001 與 ISO / IEC 27001 的基礎上導入 ISO / IEC 42001，把 AI 系統的清單、風險評估、變更與稽核納入既有的管理審查。整合的好處是沿用已熟悉的流程與稽核文化。

啟示：AI 治理不必另起爐灶，可以建構在既有的品質與資安管理體系上。

案例 36-3 產業：生成式 AI 的使用政策

許多企業在員工開始使用生成式 AI 服務後，才發現有人把原始碼、配方或客戶資料貼到外部服務。企業因此訂定使用政策：區分可用與不可用的服務、禁止輸入的資料類別、產出的審查與標示，並提供內部的替代方案（第 28 章）。

啟示：沒有政策的 AI 使用，是營業秘密外洩的高風險來源。

案例 36-4 產業：紅隊測試找出的盲點

某企業在 AI 視覺系統上線前進行紅隊測試，發現模型在照明稍微變化、或料件來自新供應商時表現明顯下降。團隊因此在驗收中加入照明與料件來源的測試，並在新料件導入時自動觸發重新驗證。

啟示：紅隊測試的價值在於上線前找出盲點，並轉化為流程的防護。

案例 36-5 台灣情境：AI 基本法與產業準備

我國《人工智慧基本法》於 2025 年 12 月 23 日三讀通過、2026 年 1 月 14 日公布施行，屬原則性的基本法，揭示人類自主、透明、公平、問責等原則。對製造業者而言，雖然具體的規範仍待各主管機關訂定，但建立 AI 系統清單、風險分級、模型卡與變更管理，是無論法規如何發展都需要的基本功；出口歐洲的業者，則需同時注意歐盟的法規時程。

啟示：提前建立治理的基本功，比等待法規明確更務實。

案例 36-6 教學情境：模型卡上的不利數字

學生團隊為專題的模型撰寫模型卡時，原本只想寫整體的正確率。指導老師要求列出各子群的結果，團隊才發現模型在夜班拍攝的影像上表現較差。他們把這個限制寫進模型卡，並在系統中對夜班的影像提高人工複判的比例。

啟示：誠實揭露限制，是可信 AI 的起點，也是改善的起點。

實作活動

活動 36-1 子群評測

以你訓練過的一個模型，依可能的條件（資料來源、時間、設備、類別）分組評測正確率與校準誤差，找出表現最差的子群並提出改善方案。

活動 36-2 AI 風險登錄

以 36.2 節的程式為範本，為你的專題或一個工業 AI 系統建立風險登錄，依 NIST AI RMF 的四項功能分類，指定控制措施與負責人。

活動 36-3 模型卡與資料卡

為你的模型撰寫模型卡與資料卡，包括預期用途、不適用的情境、子群評測、資料來源與限制，並與同學互相審查。

活動 36-4 紅隊測試

設計至少五個壓力情境（雜訊、偏移、缺值、分布外、對抗），訂定驗收標準，測試你的模型，並為未通過的項目設計防護。

活動 36-5 AI 使用政策

為一家中小企業起草生成式 AI 使用政策：可用的服務、禁止輸入的資料、產出的審查與標示、違規的處理，以及員工訓練。

活動 36-6 持續稽核

以 36.5 節的程式為範本，為你的模型登錄設計稽核規則，模擬一年的部署紀錄，找出缺失並撰寫改善計畫。

延伸閱讀

- NIST · Artificial Intelligence Risk Management Framework (AI RMF 1.0) · 2023 。
- ISO / IEC 42001:2023 · Artificial intelligence — Management system 。
- Margaret Mitchell 等 · 〈Model Cards for Model Reporting〉 · FAT* 2019 。
- Timnit Gebru 等 · 〈Datasheets for Datasets〉 · Communications of the ACM · 2021 。
- 歐盟《人工智慧法》 (Regulation (EU) 2024/1689) 及其 2026 年修正 (Regulation (EU) 2026/1744) 。

表 36-5 本章思考地圖

本章概念	關鍵提問	後續延伸閱讀
可信 AI 原則	在各子群與條件下都可靠嗎？	第 24、25 章
治理框架	用哪一個框架？如何整合既有管理系統？	第 25、35 章
風險登錄	每項風險都有人負責、有控制、有追蹤嗎？	第 37、38 章
模型卡與資料卡	用途、限制與不利的數字都揭露了嗎？	第 23、28 章
紅隊測試	驗收標準是什麼？未通過時加了什麼防護？	第 29、35 章
責任與法規	誰負責？適用哪些法規與時程？	第 32、34 章
變更與稽核	實際上有沒有照制度做？	第 38 章

章末小結

- 可信 AI 的原則包括安全、可靠與穩健、公平、透明與可解釋、隱私、問責與資安；在製造業中，公平常是關於不同產線、產品與料件的條件。範例中整體正確率約 86.6%，但 C 線只有約 78.3%、校準誤差是其他產線的三倍多，子群評測應成為驗收的標準程序。

- NIST AI RMF 以治理、對應、衡量、管理組織 AI 風險，ISO / IEC 42001 提供可驗證的 AI 管理系統。範例的風險登錄中，控制使風險分數降低約 58%，仍有 2 項中度剩餘風險需管理層接受；「無人負責」的風險靠組織而非技術解決。
- 模型卡與資料卡說明模型的用途、限制、子群表現與資料來源，自動產生可避免遺漏不利數字。紅隊測試以壓力情境與驗收標準找出弱點：範例中雜訊加倍與新產品未通過；分布外偵測只標記約 10% 的新產品，製程資訊觸發重新驗證更可靠。
- 使用 AI 不轉移專業責任；歐盟新的產品責任指令把軟體與 AI 納入產品。智慧財產涉及訓練資料、模型授權、AI 產出與營業秘密。歐盟《人工智慧法》的高風險義務經 2026 年修正延後至 2027~2028 年；我國《人工智慧基本法》已於 2026 年 1 月公布施行。
- 人類最終責任需要明確的負責人、足夠的資訊與時間、清楚的權限與獨立的安全功能。變更管理沿用工程變更流程，持續稽核檢查實際運作：範例中發現驗證逾期、未經核准部署、負責人離職與漂移未處理等 5 項缺失。AI 治理是持續運作的循環。

習題

一、選擇題

1. NIST AI RMF 的四項功能不包括？(A) 治理 (B) 對應 (C) 衡量 (D) 外包
2. 第一個 AI 管理系統的國際標準是？(A) ISO / IEC 42001 (B) ISO 9001 (C) ISO 14001 (D) IEC 62443
3. 說明模型用途、效能、限制與倫理考量的文件是？(A) 模型卡 (B) BOM (C) SOP (D) 工單
4. 模型的信心與實際正確率的一致程度稱為？(A) 校準 (B) 召回率 (C) 精確率 (D) 覆蓋率
5. 以對抗的角度刻意尋找系統弱點的測試是？(A) 紅隊測試 (B) 單元測試 (C) 回歸測試 (D) 壓力測試的同義詞
6. 分別評估模型在不同群體或條件下的表現稱為？(A) 子群評測 (B) 交叉驗證 (C) 網格搜尋

(D) 超參數調整

7. 記錄風險、評估、控制與負責人的清單是？(A) 風險登錄 (B) 料號表 (C) 設備清單

(D) 排程表

8. 歐盟新的《產品責任指令》把什麼明確納入產品？(A) 軟體與 AI 系統 (B) 不動產 (C) 服

務合約 (D) 勞務

9. 依本章，歐盟《人工智慧法》中獨立的高風險 AI 系統義務延後至何時？(A) 2025 年 8 月 (B)

2026 年 8 月 (C) 2027 年 12 月 (D) 2030 年

10. 我國《人工智慧基本法》何時三讀通過？(A) 2023 年 (B) 2024 年 (C) 2025 年 12 月

(D) 尚未通過

二、簡答題

11. 說明可信 AI 的七項原則在工業中的具體意義。

12. 為什麼整體指標可能隱藏子群的問題？如何處理表現較差的子群？

13. 比較 NIST AI RMF 與 ISO / IEC 42001 的性質與用途。

14. 風險登錄應包含哪些欄位？為什麼「無人負責」是高風險？

15. 模型卡應包含哪些內容？為什麼建議自動產生？

16. 紅隊測試未通過時，應如何處理？

17. 使用外部生成式 AI 服務有哪些智慧財產與營業秘密的風險？

18. 說明「人類最終責任」需要哪些條件才能落實。

三、計算題

19. 某模型在 A 線 1,000 件中答對 882 件、B 線 1,000 件中答對 905 件、C 線 650 件中答對 509 件，各線與整體的正確率為多少？

20. 某信心區間內有 200 個樣本，平均信心 0.90，實際答對 152 個，此區間的校準差距為多少？

21. 某風險可能性 4、影響 4，實施控制後可能性 2、影響 4，固有與剩餘風險分數各為多少？降低多

少百分比？

22. 基準正確率 89.3%，壓力情境下 82.7%，下降多少百分點？以下降 5 點為標準是否通過？

23. 驗證日為 1 月 20 日，政策要求 180 天內重新驗證，10 月 7 日時逾期多少天？（非閏年）

24. 漂移警報日為 9 月 1 日，政策要求 14 天內重新驗證，10 月 7 日時已逾期多少天？

25. 某企業有 40 個 AI 系統，其中 10% 屬高風險、30% 中風險，各有多少個？

26. 某分布外偵測在 1,000 個新產品樣本中標記 100 個，在 1,300 個正常樣本中誤標 13 個，偵測率與誤標率各為多少？

四、申論與設計題

27. 為一家中型製造企業設計 AI 治理體系：說明組織與角色、AI 系統清單與風險分級、模型卡、評測與核准、變更管理與稽核，以及與既有 ISO 體系的整合。

28. 評論以下說法：「只要 AI 的整體正確率夠高，就可以放心上線。」

29. 為一個 AI 輔助的設計工具（第 14 章）討論設計責任、智慧財產與審查流程。

五、是非題

30. 使用 AI 工具會把專業責任轉移給工具的供應商。

31. 子群評測可以發現整體指標隱藏的問題。

32. 紅隊測試未通過的模型一定不能使用。

33. 模型卡應揭露模型的限制與不利的數字。

34. ISO / IEC 42001 可以申請第三方驗證。

35. 法規時程穩定不變，不需要追蹤官方公告。

六、進階挑戰題

36. 以 NIST AI RMF 為架構，為第 28 或 29 章的系統完成一份完整的風險評估報告，包括情境對應、量化與質性的衡量、控制措施與剩餘風險的接受。

37. 建立一個自動化的模型治理流程：模型訓練後自動執行子群評測與紅隊測試，產生模型卡，未達

標準時阻擋部署，並記錄於模型登錄。

38. 比較歐盟《人工智慧法》、ISO / IEC 42001 與我國《人工智慧基本法》對工業 AI 的要求，為一家出口歐洲的台灣設備商提出合規路線圖。

七、補充題

39. 列出表 36-2 的七項可信 AI 原則。
40. 列出 NIST AI RMF 的四項功能。

提示與參考解答

1. D。
2. A。
3. A。
4. A。
5. A。
6. A。
7. A。
8. A。
9. C。
10. C。
11. 參考：安全（不導致設備損壞或傷害，安全功能獨立）、可靠（換線換料時穩定）、公平（各產線與條件表現一致）、透明（使用者知道用途與限制）、隱私（保護個人與機密資料）、問責（有人核准、負責與追溯）、資安（模型與資料完整、代理權限受控）。
12. 參考：大樣本的子群主導整體指標，小樣本子群的問題被平均掉。處理方式包括限制適用範圍、補充資料、提高人工複判比例、在介面上標示。
13. 參考：NIST AI RMF 是自願性框架，提供風險管理的方法；ISO / IEC 42001 是可驗證的管理系統

標準，用於建立並對外證明 AI 管理能力。

14. 參考：風險描述、可能性、影響、固有風險、控制措施、剩餘風險、負責人、對應的功能與檢視日期。無人負責使模型無法更新、漂移無人處理、出錯無法追溯。
15. 參考：用途與不適用情境、訓練資料、評測方法與子群結果、限制、負責人與版本。自動產生可確保與評測結果一致，不遺漏不利的數字。
16. 參考：分析原因，加上對應的防護（監控量測品質、新產品重新驗證、限制適用範圍、提高人工複判），或補充資料重新訓練，並再次測試。
17. 參考：輸入的原始碼、配方與客戶資料可能外洩或被用於訓練；產出可能涉及他人的著作權；授權條款可能限制商業使用。應訂定使用政策與內部替代方案。
18. 參考：明確的負責人、足夠的資訊與時間、清楚的權限與核准、獨立的安全功能、允許質疑 AI 的組織文化。
19. A 88.2%、B 90.5%、C 約 78.3%；整體 $(882 + 905 + 509) \div 2,650 \approx 86.6\%$ 。
20. $152 \div 200 = 0.76$ ，差距 $0.90 - 0.76 = 0.14$ 。
21. 固有 16，剩餘 8，降低 50%。
22. 6.6 點，未通過。
23. 1 月 20 日到 10 月 7 日為 260 天，逾期 80 天。
24. 9 月 1 日到 10 月 7 日為 36 天，逾期 22 天。
25. 高風險 4 個、中風險 12 個。
26. 偵測率 10%，誤標率 1%。
27. 參考：設立 AI 治理委員會與模型負責人；建立 AI 系統清單並依影響分級；每個模型有模型卡與資料卡；上線前子群評測與紅隊測試、依風險分級核准；變更沿用工程變更流程；持續稽核與管理審查；整合到 ISO 9001 / 27001 體系，視需要申請 ISO / IEC 42001 驗證。
28. 參考：不同意。整體正確率可能隱藏子群的問題、校準不佳、壓力情境下的脆弱，以及治理的空白；需要子群評測、紅隊測試、模型卡、負責人與監控。

29. 參考：工程師仍須依專業標準審查與驗證 AI 產出（模擬、測試）；記錄 AI 的使用與審查紀錄；確認訓練資料與工具的授權；完全由 AI 生成的部分在著作權與專利上可能受限，人類的創作與發明貢獻應記錄；營業秘密不輸入外部服務。
30. 否。
31. 是。
32. 否，可加上防護或限制範圍。
33. 是。
34. 是。
35. 否。
36. 提示：對應階段描述使用者、情境與可能受影響者；衡量階段結合子群評測與紅隊測試的量化結果。
37. 提示：在持續部署流程中加入評測與模型卡產生的關卡，並記錄核准者與版本。
38. 提示：先盤點產品中的 AI 功能與目標市場，判斷風險類別，再對照各法規的要求與時程。
39. 安全、可靠與穩健、公平、透明與可解釋、隱私與資料保護、問責、資安。
40. 治理、對應、衡量、管理。

第 37 章

台灣智慧製造案例研究

編著 李世淵 (機器人叫獸) | 助教 李天宇、李宇晴

本章重點

- 晶圓代工的虛擬晶圓廠、AMHS 與智慧派工
- 封裝測試的追溯與 AI 製程最佳化
- 電子製造的數位孿生與工具機熱補償
- 中小企業從單機聯網到閉環控制
- 無人機、機器人與積層製造新創

叫獸開講：同一個問題，五種答案

有一年，我帶研究生跑了一趟「台灣智慧製造之旅」：一週之內參訪了晶圓廠的參訪中心、封測廠、電子組裝廠、工具機廠，最後一站是嘉義的一家無人機新創。出發前，我給每位學生同一個問題：「這家公司的智慧製造，最想解決的是什麼問題？」

回來後的報告很有意思。晶圓廠的答案是「上千台機台、數百道工序的派工與搬運」；封測廠的答案是「每一顆晶片都要追得到來源」；電子組裝廠的答案是「產線換線快、新產品導入時間短」；工具機廠的答案是「機台熱變形與加工精度」；而那家新創公司的老闆笑著說：「我們最想解決的是——怎麼從十台做到一千台。」

一位學生在報告的最後寫道：「原來智慧製造沒有標準答案，每個產業的『痛點』決定了它的『智慧』長什麼樣子。」我很喜歡這句話。前面三十六章，我們學了感測、通訊、數位孿生、MES、AI、排程、品質、預測維護、供應鏈、資安與治理；這一章，我們把這些工具放回台灣產業的真實脈絡中，看看它們如何組合起來，解決不同產業的不同問題。

這一章，我們依產業鏈的順序走一趟：晶圓代工的派工與搬運、封裝測試的追溯與製程最佳化、電子製造與工具機的數位孿生與熱補償、中小企業從單機聯網到閉環控制的路徑，最後是無人機、機器人與積層製造的新創。每一節都以公開資料為基礎，並以一段可執行的程式重現其中的關鍵問題。

（說明：本節情境由作者綜合教學與產業參訪經驗改寫，人物與細節已調整。）

學習目標

讀完本章後，你應該能夠：

1. 說明晶圓代工的虛擬晶圓廠、AMHS 與智慧派工，並以模擬分析投料負荷、派工規則與搬運時間對生產週期的影響。
2. 說明封裝測試的追溯架構，並計算不同追溯粒度下的圍堵範圍。
3. 說明 AI 製程最佳化的方法，並以貝氏最佳化減少實驗次數。
4. 說明電子製造的數位孿生與工具機的熱變位補償，並評估感測器配置對補償效果的影響。

5. 規劃中小企業從單機聯網到閉環控制的分階段路徑，並估算各階段的效益與回收期。
6. 分析無人機、機器人與積層製造新創的製造挑戰，並從案例中歸納可遷移的經驗。

核心概念

表 37-1 本章核心名詞中英對照

中文名詞	英文	一句話說明
虛擬晶圓廠	Virtual Fab	讓客戶如同擁有自己的晶圓廠般，取得產能、進度與品質資訊的服務概念
超大型晶圓廠	GigaFab	單一廠區具超大產能的晶圓廠
自動化物料搬運系統	Automated Material Handling System, AMHS	以天車、輸送與倉儲自動搬運晶圓盒的系統
派工	Dispatching	決定機台空出時下一批要加工哪一批的規則或演算法
生產週期	Cycle Time	一批產品從投料到完工的時間
X 因子	X-Factor	生產週期除以純加工時間，衡量等待的程度
先進封裝	Advanced Packaging	以 2.5D、3D 等方式整合多顆晶粒的封裝技術
追溯	Traceability	從成品追查材料、機台、參數與人員的能力
貝氏最佳化	Bayesian Optimization	以代理模型與獲取函數選擇下一次實驗的最佳化方法
熱變位補償	Thermal Error Compensation	依溫度預測工具機熱變形並由控制器補償
智慧機上盒	Smart Machine Box, SMB	讓既有機台聯網、擷取狀態資料的裝置
閉環控制	Closed-loop Control	依量測結果自動調整製程參數

37.1 晶圓代工：虛擬晶圓廠、AMHS、先進封裝與智慧派工

37.1.1 虛擬晶圓廠與超大型晶圓廠

晶圓代工的商業模式，是讓設計公司不必擁有晶圓廠也能生產晶片。為了讓客戶「如同擁有自己

的晶圓廠」，台積電把「成為客戶的虛擬晶圓廠」(Virtual Fab) 列為公司目標——依其 1998 年年報的說法，是讓客戶享有自有晶圓廠的所有好處，卻不必承擔相應的費用與組織的複雜度：透過線上系統，客戶可以查詢產品的進度、良率與品質資料，與晶圓廠的工程師協作。這個概念今天看起來理所當然，但它其實是製造服務化 (第 32 章) 與資訊透明的早期實踐。

隨著產能規模擴大，晶圓廠走向超大型晶圓廠 (GigaFab)：一個廠區有上千台機台、數萬片晶圓同時在製。依台積電公開資料，其智慧製造涵蓋精實生產、人員生產力、機台效能、製程控制、品質保證與機器人作業等面向，並已將 AI 整合到派工系統中，擴大排程處理的範圍；自動化物料搬運系統 (AMHS) 也已在多座超大型晶圓廠中擴大運用。

37.1.2 AMHS 與智慧派工

晶圓廠的製程是「可重入」(re-entrant) 的：一片晶圓要經過數十層、數百道工序，同一組微影機台會被同一片晶圓反覆使用。晶圓盒在機台之間由天車 (overhead hoist transport, OHT) 搬運，搬運時間與等待時間往往比加工時間更長。派工的問題是：當一台機台空出來時，佇列中的哪一批應該先做？簡單的規則有先進先出、最早交期；更複雜的方法會考慮下游瓶頸是否會閒置、急件的優先順序、機台的設定切換，甚至以機器學習或強化學習學習派工策略 (第 27 章)。

晶圓廠管理中有一條重要的曲線：生產週期與負荷的關係 (operating curve)。當瓶頸機台的負荷接近 100%，等待時間會急劇上升；所以晶圓廠的產能規劃，是在產出與生產週期之間取捨。下面的模擬以 5 個機台群、4 層、20 道工序的可重入製程，比較派工規則、投料負荷與 AMHS 搬運時間的影響：

```
import numpy as np, heapq
# 晶圓廠派工模擬：可重入 (re-entrant) 的製程路線，晶圓批反覆回到微影等機台群；AMHS 搬運需要時間。
# 比較派工規則、投料負荷與 AMHS 搬運時間對生產週期與交期的影響
ROUTE = ["清洗", "薄膜", "微影", "蝕刻", "量測"] * 4      # 4 層，共 20 道工序
TOOLS = {"清洗": 2, "薄膜": 4, "微影": 3, "蝕刻": 4, "量測": 2}  # 各機台群的台數；微影是瓶頸
PT = {"清洗": 1.0, "薄膜": 2.4, "微影": 1.9, "蝕刻": 2.2, "量測": 0.9}  # 每批加工時間 (小時)
RAW = sum(PT[s] for s in ROUTE) * 1.05 + len(ROUTE) * 0.25
def simulate(rule, n_lots=400, gap=3.0, amhs=0.25, seed=1):
    rng = np.random.default_rng(seed)
    rel = np.cumsum(rng.exponential(gap, n_lots)); hot = rng.random(n_lots) < 0.1; due = rel + np.where(hot, 48, rng.uniform(60, 110, n_lots))  # 一成是急件 (交期 48 小時)
    step = np.zeros(n_lots, int); done = np.full(n_lots, np.nan)
    free = {g: [0.0] * k for g, k in TOOLS.items()}; queue = {g: [] for g in TOOLS}
    ev = [(rel[i], 0, i) for i in range(n_lots)]; heapq.heapify(ev); t = 0
    def prio(i, g):
```

```

    if rule == "先進先出": return arr[i]
    if rule == "最早交期": return due[i]
    return due[i] - (24 if hot[i] else 0)          # 交期+急件優先
arr = rel.copy()
def start(g):
    while queue[g]:
        k = int(np.argmin(free[g]))
        if free[g][k] > t + 1e-9: return
        i = min(queue[g], key=lambda j: prio(j, g)); queue[g].remove(i)
        free[g][k] = t + PT[g] * rng.uniform(0.85, 1.25)
        heapq.heappush(ev, (free[g][k], 1, i))
    while ev:
        t, kind, i = heapq.heappop(ev)
        if kind == 1:          # 一道工序完成
            g = ROUTE[step[i]]; step[i] += 1
            if step[i] == len(ROUTE): done[i] = t
            else: heapq.heappush(ev, (t + amhs, 0, i))      # AMHS 搬運到下一站
            start(g)
        if kind == 0:
            g = ROUTE[step[i]]; arr[i] = t; queue[g].append(i); start(g)
    ct = done - rel; late = np.maximum(done - due, 0)
    x = np.mean(ct) / RAW          # X 因子：生產週期 ÷ 純加工與搬運時間
    return np.mean(ct), np.mean(done > due), np.mean(done[hot] > due[hot]), x
def avg(rule, **kw): return np.mean([simulate(rule, seed=s, **kw) for s in range(1, 9)],
axis=0) # 8 次模擬平均
for r in ["先進先出", "最早交期", "交期+急件優先"]:
    ct, late, hl, x = avg(r, gap=2.7)
    print(f"{r}: 平均生產週期 {ct:.1f} 小時 (X 因子 {x:.2f}), 延遲比例 {late:.0%}, 急件延遲比例 {hl:.0%}")
for gap in [3.4, 3.0, 2.8, 2.7]:
    ct, late, hl, x = avg("交期+急件優先", gap=gap); u = sum(PT[s] for s in ROUTE if s == "微影") * 1.05 / (TOOLS["微影"] * gap)
    print(f"投料間隔 {gap} 小時 (微影負荷 {u:.0%}): 生產週期 {ct:.1f} 小時, X 因子 {x:.2f}, 延遲比例 {late:.0%}")
for a in [0.25, 1.0]:
    ct, late, hl, x = avg("交期+急件優先", gap=2.7, amhs=a); print(f"AMHS 每次搬運 {a} 小時: 生產週期 {ct:.1f} 小時, 延遲比例 {late:.0%}")

```

執行結果：在微影負荷約 99% 時，先進先出的平均生產週期為 70.3 小時 (X 因子 1.75)，延遲比例 32%，急件延遲比例 74%；最早交期為 60.7 小時 (X 因子 1.51)，延遲比例 16%，急件延遲比例 21%；交期 + 急件優先為 61.1 小時，延遲比例 16%，急件延遲比例降到 8%。投料間隔從 3.4、3.0、2.8 縮短到 2.7 小時，微影負荷從 78%、89%、95% 升到 99%，生產週期依序為 43.6、48.3、54.9、61.1 小時，X 因子從 1.08 升到 1.52，延遲比例從 0% 升到 16%。AMHS 每次搬運從 0.25 小時增加到 1.0 小時，生產週期從 61.1 小時增加到 74.6 小時，延遲比例從 16% 升到 35%。

結果顯示三件事。第一，派工規則有用，但有其限度：在高負荷下，最早交期比先進先出縮短約 14% 的生產週期，延遲比例從 32% 降到 16%；再加上急件優先，急件的延遲比例從 21% 降到 8%，整體指標幾乎不變——派工的取舍常是「誰先」，而不是「全部都更快」。第二，負荷的影響遠大於

派工規則：瓶頸負荷從 78% 提高到 99%，生產週期從 43.6 小時增加到 61.1 小時，X 因子從 1.08 升到 1.52。這說明為何晶圓廠願意保留一些產能餘裕。第三，搬運不是小事：可重入的製程有數十到數百次搬運，每次多 45 分鐘，生產週期就增加約 22%。這正是 AMHS 的天車速度、路徑與派車演算法值得大量投資的原因。




圖 37-1 晶圓廠的負荷曲線：瓶頸負荷愈接近 100%，生產週期愈長

37.1.3 先進封裝與智慧後段廠

AI 晶片的需求推動了先進封裝的快速成長：把邏輯晶片與高頻寬記憶體以 2.5D 或 3D 的方式整合在一起。依台積電 2023 年 6 月的公開新聞，其位於竹南科學園區的先進封測六廠是當時規模最大的先進封測廠，提供 SoIC、InFO、CoWoS 與測試等 3DFabric 整合服務；廠內的自動物料搬運系統總長超過 32 公里，並導入智慧製造以進行製程控制與即時異常偵測，資料處理能力據稱達前段晶圓廠的 500 倍。

先進封裝讓前段與後段的界線變得模糊：後段也需要晶圓級的製程控制、更精密的追溯（每顆晶粒來自哪片晶圓的哪個位置），以及跨廠的資料整合。這也呼應了第 33 章的供應鏈：先進封裝的產能，常是 AI 晶片供應的瓶頸。

表 37-2 晶圓代工的智慧製造重點（依公開資料整理）

面向	問題	方法	本書相關章節
派工與排程	上千台機台、可重入流程、急件	派工規則、AI 派工、負荷規劃	第 27 章

面向	問題	方法	本書相關章節
物料搬運	搬運時間與壅塞	AMHS、天車派車、路徑最佳化	第 10、27 章
製程控制	先進製程的變異收斂	R2R、虛擬量測、AI 分析	第 25 章
設備	機台效能與異常	FDC、預測維護	第 26 章
客戶協作	進度、良率與品質的透明	虛擬晶圓廠、線上服務	第 32 章
先進封裝	前後段整合、晶粒追溯	晶圓級製程控制、追溯	第 25、33 章

37.2 封裝測試：追溯、智慧物流與 AI 製程最佳化

37.2.1 封測的智慧化歷程

封裝測試是勞力與設備密集的產業：黏晶、打線、封膠、切割、測試，每一站都有大量的機台與物料。依公開報導，日月光自 2015 年起規劃自動化的「關燈工廠」，2018 年被視為其 AI 元年，2021 年建構 AI 平台，至 2024 年已完成 56 座智慧工廠；報導中提到，高雄廠導入 AI 於生產排程、自動化調度與良率提升後，生產效率提升 67%、訂單交期縮短 39%，並培育了超過 700 位自動化工程師。這些數字來自企業的公開說明，不同的計算基準可能不同，但它清楚呈現了一個方向：封測的智慧化從自動搬運開始，逐步走向資料與 AI。

37.2.2 追溯：從生產批到每一顆

客戶，特別是車用與高可靠度應用的客戶，要求封測廠能夠追溯每一顆晶片：用了哪一片晶圓、哪一個位置的晶粒、哪一批基板、錫線、封膠，在哪台機台、什麼參數、哪個班別生產。追溯的粒度決定了出問題時要圍堵多少產品。下面的模擬假設某一批封膠被發現有問題，比較三種追溯粒度的圍堵範圍：

```
import numpy as np
# 封測追溯：一顆 IC 由晶圓批的晶粒、基板條、錫線與封膠等材料組成。某一批封膠被發現有問題時，比較
# 「生產批層級」「班別層級」與「單顆層級」的追溯，需要圍堵的數量差多少
rng = np.random.default_rng(7)
N_LOTS, PER_LOT = 24, 2000                                # 24 個生產批，每批 2,000 顆
units = []                                                  # 每顆：(生產批，班別，封膠批，晶圓批)
mold_lot, used = 0, 0; cap = rng.integers(2500, 4500)
for lot in range(N_LOTS):
    shift = lot // 4                                       # 每個班別處理 4 個生產批
    wafer = lot // 2
```

```

for u in range(PER_LOT):
    if used >= cap: mold_lot += 1; used = 0; cap = rng.integers(2500, 4500) # 封膠罐
    用完就換下一批
    units.append((lot, shift, mold_lot, wafer)); used += 1
units = np.array(units)
def scope(bad):
    hit = units[:, 2] == bad
    lots = np.unique(units[hit, 0]); shifts = np.unique(units[hit, 1])
    return {"班別層級": np.isin(units[:, 1], shifts).sum(), "生產批層級": np.isin(units[:, 0], lots).sum(), "單顆層級": hit.sum()}
print(f"共 {len(units):,} 顆、{units[:, 2].max() + 1} 批封膠；假設編號 6 的封膠批有問題")
for k, v in scope(6).items(): print(f"{k}追溯：需圍堵 {v:,} 顆（為實際受影響數量的 {v / scope(6)['單顆層級']:.1f} 倍）")
r = np.array([list(scope(b).values()) for b in range(units[:, 2].max() + 1)])
print(f"對每一批封膠平均：班別層級 {r[:, 0].mean():,.0f} 顆、生產批層級 {r[:, 1].mean():,.0f} 顆、單顆層級 {r[:, 2].mean():,.0f} 顆")

```

執行結果：共 48,000 顆、13 批封膠；假設編號 6 的封膠批有問題，班別層級的追溯需圍堵 8,000 顆（實際受影響數量的 1.9 倍），生產批層級需圍堵 6,000 顆（1.4 倍），單顆層級只需圍堵實際受影響的 4,167 顆。對每一批封膠平均，三種粒度的圍堵數量分別約為 11,077、5,538 與 3,692 顆。

只知道「哪個班別用了哪一批封膠」時，平均要圍堵約 1.1 萬顆；知道到生產批，降到約 5,500 顆；精確到每一顆，只需約 3,700 顆——約為班別層級的三分之一。單顆追溯需要的不只是在每顆產品上打標記（如二維條碼），還要在材料更換的時刻精確記錄「從哪一顆開始換了料」：這需要機台與 MES 的整合（第 11、17 章）、上料時的條碼掃描與防呆，以及資料模型的設計（第 20、23 章）。




圖 37-2 追溯粒度與圍堵範圍：粒度愈細，需圍堵的產品愈少

37.2.3 智慧物流

封測廠的物料種類多、批量小、換線頻繁。智慧物流包括自動倉儲、自主移動機器人 (AMR) 在站點之間搬運料盒與治具、上料時的條碼核對防止用錯料，以及依排程預先備料。與晶圓廠的 AMHS 相比，封測廠的搬運對象更多樣，常需要結合 AMR、輸送帶與人工的混合系統；派車的演算法與晶圓廠相似，但更強調彈性與防錯。

37.2.4 AI 製程最佳化：以更少的實驗找參數

打線 (wire bonding) 的品質取決於超音波功率、壓力、時間與溫度等參數。新材料或新產品導入時，工程師需要以實驗找出參數。傳統的格點實驗，4 個參數各 3 個水準就要 81 次；貝氏最佳化則以高斯過程建立「參數→品質」的代理模型，並依「期望改善量」選擇下一次最值得做的實驗：

```
import numpy as np, warnings; warnings.filterwarnings("ignore")
from sklearn.gaussian_process import GaussianProcessRegressor
from sklearn.gaussian_process.kernels import Matern, WhiteKernel
from scipy.stats import norm
# AI 製程最佳化：打線 (wire bonding) 的超音波功率、壓力、時間與溫度影響鉚點的推力 (shear)。以高斯過程代理模型的貝氏最佳化，與傳統的格點實驗比較：用較少的實驗找到較好的參數
LO, HI = np.array([40, 15, 8, 140]), np.array([100, 45, 20, 200]) # 功率 %、壓力 gf、時間 ms、溫度 °C
def shear(x, rng=None): # 真實的製程響應 (實務上未知)，單位 gf
    z = (np.atleast_2d(x) - LO) / (HI - LO)
    y = 30 - 40 * (z[:, 0] - 0.62) ** 2 - 25 * (z[:, 1] - 0.45) ** 2 - 12 * (z[:, 2] - 0.7) ** 2 - 8 * (z[:, 3] - 0.55) ** 2 + 10 * (z[:, 0] - 0.62) * (z[:, 1] - 0.45)
    return y + (rng.normal(0, 0.6, len(y)) if rng is not None else 0)
def grid(levels=3):
    g = np.array(np.meshgrid(*[np.linspace(0.1, 0.9, levels)] * 4)).reshape(4, -1).T
    return LO + g * (HI - LO)
def bayes_opt(n_init=8, n_iter=17, seed=0):
    rng = np.random.default_rng(seed); X = LO + rng.random((n_init, 4)) * (HI - LO); y = shear(X, rng)
    gp = GaussianProcessRegressor(Matern(length_scale=np.ones(4), nu=2.5) + WhiteKernel(0.3, (0.01, 10)), normalize_y=True)
    for _ in range(n_iter):
        gp.fit((X - LO) / (HI - LO), y); C = rng.random((4000, 4)); mu, sd = gp.predict(C, return_std=True)
        imp = mu - y.max(); z = imp / (sd + 1e-9); ei = imp * norm.cdf(z) + sd * norm.pdf(z) # 期望改善量
        xn = LO + C[np.argmax(ei)] * (HI - LO); X = np.vstack([X, xn]); y = np.append(y, shear(xn, rng))
        gp.fit((X - LO) / (HI - LO), y); best = X[np.argmax(gp.predict((X - LO) / (HI - LO)))] # 以模型預測選出最佳點，避免被雜訊誤導
    return X, y, best
G = grid(3); rng = np.random.default_rng(1); yg = shear(G, rng); bg = G[np.argmax(yg)]
print(f"格點實驗 (每個參數 3 水準)：{len(G)} 次實驗，最佳參數 {np.round(bg).astype(int)}，真實推力 {shear(bg)[0]:.1f} gf")
X, y, bb = bayes_opt()
print(f"貝氏最佳化：{len(X)} 次實驗，最佳參數 {np.round(bb).astype(int)}，真實推力 {shear(bb)[0]:.1f} gf")
```

```
res = [shear(bayes_opt(seed=s)[2])[0] for s in range(10)]
print(f"貝氏最佳化重複 10 次：真實推力平均 {np.mean(res):.1f} gf（最差 {min(res):.1f}）；理論最佳約 {shear(LO + np.array([0.62, 0.45, 0.7, 0.55]) * (HI - LO))[0]:.1f} gf")
```

執行結果：格點實驗（每個參數 3 水準）共 81 次實驗，找到的最佳參數為功率 70%、壓力 30 gf、時間 19 ms、溫度 170°C，真實推力 28.8 gf；貝氏最佳化以 25 次實驗找到功率 81%、壓力 31 gf、時間 16 ms、溫度 173°C，真實推力 29.6 gf。貝氏最佳化重複 10 次，真實推力平均 29.2 gf，最差 27.9 gf；理論最佳約 30.0 gf。

貝氏最佳化以 25 次實驗找到的參數，平均表現略優於 81 次的格點實驗，實驗次數減少約七成；但它不保證每次都更好——10 次重複中最差的一次只有 27.9 gf。實務上，貝氏最佳化常與實驗設計（第 25 章）結合：先以少量的設計點了解響應的大致形狀，再以貝氏最佳化細調；找到的參數仍須以確認實驗與製程能力分析驗證，並記錄在變更管理中（第 36 章）。




圖 37-3 格點實驗與貝氏最佳化：以約三成的實驗次數找到相當或更好的參數

37.3 電子製造與工具機：數位學生、AI 視覺與設備聯網

37.3.1 電子製造：模擬先行的工廠

台灣的電子製造服務（EMS）與 ODM 業者，為全球組裝伺服器、筆電與各式電子產品。這個產業的特點是產品生命週期短、換線頻繁、客戶要求快速量產；近年 AI 伺服器的需求更讓產線的規劃與擴建加速。依 NVIDIA 於 2025 年 5 月發布的公開文章，多家台灣製造業者以 Omniverse 等平台建立工廠的數位學生：鴻海以其數位學生平台規劃機器人工作站與廠房配置，並據稱以數位學生進行熱

評估的速度提升 150 倍；緯創以「模擬先行」的方式規劃機械手臂，據稱每支手臂的組裝時間縮短 12 秒；和碩以視覺 AI 代理，據稱降低 7% 的人力成本與 67% 的缺陷率；台積電則把廠房的 2D 設計轉為 3D 配置，以 AI 檢查設備碰撞並快速產生管線配置。這些數字來自廠商與平台供應商的公開說法，細節與計算基準並不完整，閱讀時應視為「方向」而非可直接比較的指標。

這些案例共同的邏輯是第 19~21 章的數位孿生：在虛擬環境中先規劃、模擬與驗證，再到實體工廠建置。對於擴建速度很快的 AI 伺服器產線，模擬先行可以減少試誤的時間與成本；而 AI 視覺（第 24 章）、機器人（第 10、30 章）與 MES（第 17 章）則讓產線在量產後持續改善。

37.3.2 工具機：從機台聯網到加工精度

台灣是全球主要的工具機出口國之一，中部的精密機械聚落有大量的整機廠與零組件廠。工具機的智慧化有兩條主線。第一條是聯網：依經濟部工業局的公開資料，自 2018 年起推動的智慧機上盒（SMB）讓大量既有機台可以擷取狀態與加工資料（第 32 章），這是後續分析與服務的基礎。第二條是精度：工具機加工時，主軸與馬達發熱使結構產生熱變形，熱變位可達數十微米，是精密加工最主要的誤差來源之一。熱變位補償以機台上的溫度感測器預測熱變形，由控制器即時補償。

37.3.3 範例：工具機的熱變位補償

下面的模擬以一階熱模型產生主軸前軸承、主軸馬達、立柱與床台的溫度，以及 Z 軸的熱變位；以 5 天、環境約 24°C 的實測資料建立補償模型，比較三種感測器配置在同季節與夏天的補償效果：

```
import numpy as np
from sklearn.linear_model import Ridge
# 工具機熱變位補償：主軸運轉發熱使 Z 軸伸長數十微米。以機台上的溫度感測器（主軸前軸承、主軸馬達、
# 立柱、床台、環境）建立熱變位模型，由控制器即時補償；並檢查模型在不同季節（環境溫度）下是否仍然有效
rng = np.random.default_rng(3)
def run(hours=8, amb0=24.0, seed=0):
    r = np.random.default_rng(seed); t = np.arange(0, hours * 60, 1.0) # 每分鐘
    # 一筆
    speed = np.repeat(r.choice([0, 6000, 10000, 15000], int(np.ceil(len(t) / 40))),
    40)[:len(t)] # 主軸轉速每 40 分鐘變一次
    amb = amb0 + 1.5 * np.sin(2 * np.pi * t / (24 * 60)) + r.normal(0, 0.05, len(t))
    T = np.zeros((len(t), 4)); Tb = np.array([amb0] * 4); tau = [12, 25, 90, 180]; gain =
    [9e-4, 6e-4, 2e-4, 0.5e-4]
    for k in range(len(t)): # 一階熱
    # 模型：各部位以不同的時間常數升溫
        target = amb[k] + np.array(gain) * speed[k]; Tb = Tb + (target - Tb) /
    np.array(tau); T[k] = Tb
    X = np.column_stack([T - amb[:, None], amb - 20]) # 特徵：
    # 各部位相對環境的溫升，以及環境溫度
```

```

dz = 2.6 * X[:, 0] + 1.4 * X[:, 1] + 3.2 * X[:, 2] - 1.8 * X[:, 3] + 0.8 * X[:, 4] +
r.normal(0, 0.8, len(t)) # Z 軸熱變位 (μm)
return X + r.normal(0, 0.05, X.shape), dz
FEATS = {"只用前軸承溫度": [0], "四個機台溫度 (不含環境)": [0, 1, 2, 3], "四個機台溫度+環境溫度": [0, 1, 2, 3, 4]}
Xtr, ytr = map(np.concatenate, zip(*[run(seed=s) for s in range(5)])) # 以 5 天、環境約 24°C 的實測資料建模
tests = {"同季節的新的一天": run(amb0=24.0, seed=11), "夏天 (環境 30°C)": run(amb0=30.0, seed=12)}
for tn, (X, y) in tests.items(): print(f"{tn}: 未補償最大誤差 {np.abs(y).max():.1f} μm, 標準差 {y.std():.1f} μm")
for fn, idx in FEATS.items():
    m = Ridge(alpha=1.0).fit(Xtr[:, idx], ytr)
    print(f"{fn}: " + " ".join(f"{tn}補償後最大 {np.abs(y - m.predict(X[:, idx])).max():.1f} μm (標準差 {(y - m.predict(X[:, idx])).std():.1f}) " for tn, (X, y) in tests.items()))

```

執行結果：同季節的新的一天，未補償的最大誤差為 55.5 μm (標準差 15.4 μm)；夏天 (環境 30°C) 為 63.8 μm (標準差 15.6 μm)。只用前軸承溫度的模型，補償後的最大誤差在同季節為 7.7 μm、夏天為 10.7 μm；四個機台溫度 (不含環境) 的模型，同季節為 2.5 μm、夏天為 7.4 μm；四個機台溫度加上環境溫度的模型，同季節為 2.3 μm、夏天為 2.7 μm。

這個結果有兩個啟示。第一，感測器配置很重要：只用一個溫度感測器，雖然能把誤差從數十微米降到十微米以內，但不同部位的時間常數不同，單點溫度無法完整描述結構的熱狀態；增加立柱與床台的溫度後，誤差再降到約 2.5 μm。第二，模型要在「沒見過的條件」下驗證：不含環境溫度的模型，在同季節的表現幾乎一樣好，但到了夏天，最大誤差從 2.5 μm 增加到 7.4 μm (標準差不變，代表出現了系統性的偏移)。這與第 36 章的紅隊測試同一個道理：訓練資料只涵蓋一個季節時，模型的弱點要靠刻意設計的測試才看得出來。




圖 37-4 工具機熱變位補償：感測器配置與季節對補償效果的影响

37.3.4 設備聯網的商業模式

工具機廠的智慧化不只為了自己的工廠，也成為產品的一部分：聯網的機台可以提供遠端監控、預測維護、加工參數建議與熱補償的更新，從賣機台走向賣服務（第 32 章）。這也帶來新的責任：遠端連線的資安（第 35 章）、資料的權利歸屬（第 32 章），以及補償模型更新的變更管理（第 36 章）。

表 37-3 電子製造與工具機的智慧製造重點（依公開資料整理）

產業	主要問題	智慧製造的做法	本書相關章節
電子製造（EMS / ODM）	換線頻繁、擴建快、新品導入	數位孿生規劃、模擬先行、AI 視覺、機器人	第 19～21、24、30 章
伺服器組裝與測試	大型系統的組裝、測試與追溯	測試資料分析、追溯、排程	第 17、25、27 章
工具機整機廠	加工精度、服務化	熱補償、聯網、遠端服務	第 9、26、32 章
工具機使用者	稼動率、品質	智慧機上盒、OEE、刀具管理	第 8、9、26 章

37.4 中小企業：從單機聯網到閉環控制

37.4.1 中小企業的處境

台灣的製造業以中小企業為主體。許多加工廠只有十幾台機台、幾十位員工，沒有資訊部門，老闆同時是業務、廠長與工程師。這些企業面對的問題很具體：人力不足、師傅退休、訂單少量多樣、交期壓力大、客戶要求追溯與碳排資料（第 34 章）。他們不需要（也負擔不起）一次到位的「智慧工廠」，需要的是一條能逐步投資、每一步都看得到效益的路徑。

37.4.2 分階段的路徑

本書建議的路徑分為四個階段（圖 37-6）。第一階段是「看得見」：以智慧機上盒或機台控制器的通訊介面，讓每台機台的狀態、停機原因與產量即時可見，停機時通知負責人（第 11、17 章）。第二階段是「管得好」：建立簡易的 MES 或工單系統，記錄工單、品質與追溯資料，計算 OEE 並找出主要的損失（第 8、17 章）。第三階段是「算得準」：以資料預測刀具磨耗、排定工單、

估算報價與交期（第 23、26、27 章）。第四階段是「自己調」：依量測結果自動補償刀具與製程參數，形成閉環控制（第 25 章）。每一階段都應先選一個痛點、一兩台機台試行，確認效益後再擴大。

37.4.3 範例：分階段投資的效益

下面的模擬以一家有 12 台 CNC 的加工廠為例，估算現況、階段一（單機聯網與停機通知）與階段二（刀具磨耗預測與閉環補償）的 OEE、報廢與每階段的回收期：

```
import numpy as np
# 中小企業的智慧化路徑：一家有 12 台 CNC 的加工廠，分三階段投資—(0) 現況：靠巡視發現停機；(1)
單機聯網與停機通知；(2) 加上刀具磨耗預測與尺寸量測的閉環補償。估算各階段的 OEE、報廢率與投資回收期
MACHINES, DAYS, SHIFT = 12, 22, 16 * 60 # 每月 22 天、每天兩班共 16 小
時（分鐘）
STAGES = { # 名稱：（停機發現延遲 分鐘、刀具意外斷裂率、報廢率、累計投資 萬元）
    "現況（巡視）": (20, 0.040, 0.030, 0),
    "階段一：單機聯網與通知": (8, 0.040, 0.030, 150),
    "階段二：刀具預測與閉環補償": (8, 0.012, 0.009, 380)}
def month(delay, brk, scrap, seed=0):
    r = np.random.default_rng(seed); avail = perf = qual = 0; good = 0
    for _ in range(MACHINES * DAYS):
        stops = r.poisson(5); down = sum(delay + r.exponential(12) for _ in range(stops))
# 換料、夾治具、警報等小停機
        down += r.binomial(1, brk) * (90 + delay)
# 刀具意外斷裂：換刀、首件檢查
        run = SHIFT - 45 - down; parts = run / 6.0 * r.uniform(0.86, 0.94)
# 計畫停機 45 分鐘；標準工時 6 分鐘／件
        g = parts * (1 - scrap - r.binomial(1, brk) * 0.004)
        avail += run / (SHIFT - 45); perf += parts * 6.0 / run; qual += g / parts; good
    += g
    n = MACHINES * DAYS; return avail / n, perf / n, qual / n, good
prev = None
for name, (d, b, s, inv) in STAGES.items():
    a, p, q, g = month(d, b, s); oee = a * p * q; scrap_n = g / q * (1 - q)
    msg = f"{name}：稼動率 {a:.1%}，性能 {p:.1%}，良率 {q:.1%}，OEE {oee:.1%}，月良品
{g:,.0f} 件，月報廢 {scrap_n:,.0f} 件"
    if prev: # 本階段相對上一階段的效益：多出的良品（邊際貢獻 40 元／件，假設訂單充足）+ 少報
廢的材料與工時（150 元／件）
        val = ((g - prev[0]) * 40 + (prev[1] - scrap_n) * 150) / 1e4
        msg += f"；本階段每月效益約 {val:.1f} 萬元，本階段投資 {inv - prev[2]} 萬元，回收約
{(inv - prev[2]) / val:.0f} 個月"
    print(msg); prev = (g, scrap_n, inv)
```

執行結果：現況的稼動率為 82.4%、性能 90.1%、良率 97.0%，OEE 72.0%，每月良品 28,958 件、報廢 899 件。階段一導入單機聯網與停機通知後，停機的發現時間從平均 20 分鐘縮短到 8 分鐘，稼動率提高到 88.9%，OEE 77.6%，每月良品 31,248 件；本階段每月效益約 8.1 萬元，投資 150 萬元，約 19 個月回收。階段二加上刀具預測與閉環補償後，良率提高到 99.1%，OEE 79.5%，每月

報廢降到 292 件；本階段每月效益約 13.2 萬元，投資 230 萬元，約 17 個月回收。

這個簡化的估算說明了幾件事。第一，最便宜的一步常是效益最明顯的一步：讓停機「被看見」，就能把稼動率提高約 6.5 個百分點。第二，不同階段的效益來源不同：階段一主要增加產出，前提是訂單充足；階段二主要減少報廢與刀具意外，即使訂單不足也有價值。第三，回收期對假設很敏感——邊際貢獻、材料成本、停機發現時間都會大幅改變結果；企業應以自己的資料試算，並在試行後以實際數字修正（活動 37-4）。




圖 37-5 中小企業分階段導入的 OEE 與報廢變化



圖 37-6 中小企業的智慧化路徑：看得見、管得好、算得準、自己調

37.4.4 常見的陷阱

中小企業的智慧化常見幾個陷阱：買了系統但沒有人看資料；資料有了但停機原因沒有人填，分析不出結果；一次導入太多功能，現場無法消化；過度依賴單一的系統供應商；忽略資安，讓機台的遠端連線成為破口（第 35 章）。避免這些陷阱的關鍵是：從痛點出發、指定負責人、先求有再求好、每一步都量化效益，並善用政府計畫與法人的輔導資源。

37.5 無人機、機器人與積層製造新創

37.5.1 從十台到一千台

新創公司的製造挑戰，和大企業很不一樣。大企業的問題是「如何讓上千台機台更有效率」，新創的問題是「如何從原型走到量產」：設計要能製造（DFM）、零件要找得到穩定的供應商、品質系統要從無到有、產品要通過認證，而且這一切都要在資金燒完之前完成。智慧製造的工具在這裡的角色不同：數位孿生與模擬可以減少實體試作的次數（第 19、21 章），MES 與追溯從第一台開始就建立（第 17 章），供應鏈的透明與元件來源（第 33、35 章）則可能是能否打進國際市場的關鍵。

37.5.2 無人機：民主供應鏈與產業聚落

依公開報導，經濟部支持的「台灣卓越無人機海外商機聯盟」於 2024 年 9 月成立，集結了五十多家國內企業，包括雷虎科技、中光電智能機器人、經緯航太、長榮航太、亞洲航空與宏碁等，目標是整合系統能力、爭取國際的政府間訂單，並以「非紅供應鏈」為訴求。嘉義縣的「亞洲無人機 AI 創新應用研發中心」吸引了超過 50 個產官學單位進駐，依 2024 年 12 月的報導，行政院已核定增建第二棟。這些發展讓無人機從少量的專案生產，走向需要量產能力的產業：零組件的國產化、飛控與通訊模組的品質一致性、整機的測試與追溯，以及元件來源的證明。

對無人機新創而言，元件來源的證明特別重要：國際客戶可能要求證明飛控、通訊、相機與馬達等關鍵元件不來自特定國家。這需要從採購開始建立元件的來源紀錄，與第 35 章的 SBOM、第 33 章的數位產品護照是同一種能力——只是對象從軟體擴大到硬體。

37.5.3 機器人：把 AI 內建在產品中

台灣的機器人產業以零組件（減速機、線性滑軌、伺服馬達）與協作型機器人見長。依公開報導，達明機器人源自廣明光電的實驗團隊，產品以「內建視覺與 AI 推論」為特色，讓機器人出廠即可進行定位、辨識、量測與檢測，降低系統整合的成本；該公司於 2025 年 9 月上市。行政院也在 2025 年 5 月通過「智慧機器人產業推動方案」，以應對缺工與高齡照護的需求，並結合南部的研發據點。

機器人新創的製造挑戰，在於精密零組件的品質一致性、每台機器人的校正與測試，以及軟體版

本的管理：當 AI 與視覺內建在產品中，模型的更新就成為產品的變更（第 36 章），需要版本管理、驗證與追溯；而機器人的安全功能與 AI 的功能必須分離（第 30 章）。

37.5.4 積層製造：從原型到量產零件

積層製造（第 15、16 章）在台灣的應用，從原型製作逐步走向醫材、模具隨形冷卻水路、航太與半導體設備的零件。法人研究機構與業者投入金屬積層製造的設備、材料與製程開發。積層製造的智慧化重點是製程監控與品質保證：每一層的熔池影像、溫度與雷射參數都可以記錄，用以預測缺陷並建立每一個零件的「數位履歷」。對量產零件而言，挑戰不在能不能印出來，而在每一次都印得一樣：這需要製程參數的鎖定、粉末批次的追溯、後處理的控制，以及以統計方法證明製程能力（第 25 章）。

表 37-4 新創的製造挑戰與本書的工具

挑戰	說明	本書的工具
從原型到量產	設計可製造、試作次數多	數位孿生與模擬（第 19、21 章）、DFM（第 13 章）
品質系統從無到有	客戶與認證的要求	SPC 與製程能力（第 25 章）、MES 與追溯（第 17 章）
元件來源的證明	國際客戶的供應鏈要求	SBOM 與元件來源（第 33、35 章）
小量多樣的生產	換線與排程	排程（第 27 章）、彈性自動化（第 10 章）
內建 AI 的產品	模型更新即產品變更	模型治理（第 36 章）、機能安全（第 30 章）
資金與人力有限	不能一次到位	分階段導入（37.4 節）、雲端與開源工具

案例

案例 37-1 教學情境：同一個問題，五種答案

這是本章開頭的情境。學生參訪晶圓廠、封測廠、電子組裝廠、工具機廠與無人機新創，發現每個產業的智慧製造都從不同的痛點出發：派工與搬運、追溯、換線與新品導入、加工精度、從原型到量產。

啟示：智慧製造沒有標準答案，痛點決定了「智慧」的樣子。

案例 37-2 產業：晶圓代工廠成為燈塔工廠

依聯電 2025 年 1 月的公開新聞，其台南的 Fab 12A 被世界經濟論壇列入全球燈塔網路，並稱是全球第一座獲得此認可的晶圓代工廠。新聞提到該廠導入超過 48 項第四次工業革命的解決方案，其中近 95% 為自行開發；應用包括以機器學習縮短設計套件的製作時間、瓶頸機台的預測模型、以影像辨識進行缺陷根因分析，以及在 AMHS 中以 AI 演算法從約 6,800 萬種可能的路徑中，為晶圓在約 3,000 台設備間選擇最佳路徑。

啟示：派工與搬運（37.1 節）是晶圓廠智慧製造的核心，而自行開發的能力讓解決方案能貼近現場。

案例 37-3 產業：封測廠的智慧化歷程

依公開報導，日月光自 2015 年起規劃自動化工廠，2018 年被視為其 AI 元年，2021 年建構 AI 平台，至 2024 年已完成 56 座智慧工廠；高雄廠導入 AI 於排程、調度與良率提升後，據稱生產效率提升 67%、訂單交期縮短 39%，並培育了超過 700 位自動化工程師。

啟示：智慧化是十年以上的歷程，而人才的培育與技術的投資同等重要。

案例 37-4 產業：高度自動化的先進封測廠

依台積電 2023 年 6 月的公開新聞，竹南的先進封測六廠提供 SoIC、InFO、CoWoS 與測試服務，AMHS 總長超過 32 公里，並以智慧製造進行製程控制與即時異常偵測。先進封裝的產能，近年成為 AI 晶片供應的關鍵之一。

啟示：先進封裝讓後段製程也需要前段等級的自動化、資料與追溯。

案例 37-5 台灣情境：無人機國家隊與產業聚落

依公開報導，台灣卓越無人機海外商機聯盟於 2024 年 9 月成立，集結五十多家企業爭取國際訂單；嘉義的亞洲無人機 AI 創新應用研發中心吸引超過 50 個單位進駐並規劃擴建。從專案生產走

向量產，需要零組件國產化、品質一致性與元件來源的證明。

啟示：產業聚落與供應鏈透明，是新興產業走向國際市場的基礎。

案例 37-6 教學情境：第一台聯網的機台

一家十幾台 CNC 的加工廠，老闆一開始只願意讓一台機台試著聯網。兩週後，他看到那台機台每天有將近一小時的「等待換料」，原因是材料常放在倉庫另一頭。調整物料擺放與換料的通知後，這台機台的稼動率明顯提高；老闆隨即決定讓其他機台也聯網，並開始記錄停機原因。

啟示：中小企業的智慧化，從一個看得見的效益開始。

實作活動

活動 37-1 晶圓廠的負荷曲線

修改 37.1 節的模擬，改變瓶頸機台的台數、加工時間的變異與急件的比例，畫出生產週期與負荷的關係曲線，並設計一個你認為更好的派工規則，與先進先出、最早交期比較。

活動 37-2 追溯粒度的成本效益

延伸 37.2 節的模擬，估算單顆追溯所需的標記與資料成本，並與圍堵範圍縮小所節省的檢驗、報廢與客戶損失比較，找出損益兩平的不良發生率。

活動 37-3 貝氏最佳化的實驗設計

以 37.2 節的打線模型為例，比較不同的初始實驗數、獲取函數與實驗雜訊對貝氏最佳化結果的影響，並設計一份給工程師的實驗計畫。

活動 37-4 中小企業的導入計畫

訪問一家中小型製造企業（或以老師提供的情境），找出前三大痛點，依 37.4 節的四個階段提出分階段的導入計畫，並以 t5 的方法估算各階段的效益與回收期。

活動 37-5 產業案例研究

選擇一家台灣的製造企業，蒐集其公開資料（年報、永續報告書、新聞、技術論文），整理其智慧製造的痛點、做法、成果與本書的相關章節，並區分企業的宣稱與可查證的事實。

活動 37-6 新創的量產準備清單

為一家無人機或機器人新創，製作從原型到量產的準備清單，涵蓋 DFM、供應商、品質系統、追溯、元件來源與軟體版本管理。

延伸閱讀

- Wallace J. Hopp、Mark L. Spearman，〈Factory Physics〉，第 3 版，Waveland Press，2008。
- Bobak Shahriari 等，〈Taking the Human Out of the Loop: A Review of Bayesian Optimization〉，Proceedings of the IEEE，104(1)，2016。
- R. Ramesh、M. A. Mannan、A. N. Poo，〈Error compensation in machine tools — a review. Part II: thermal errors〉，International Journal of Machine Tools and Manufacture，40(9)，2000。
- World Economic Forum，Global Lighthouse Network 年度報告。
- 台積電、聯電、日月光等企業的年報、永續報告書與智慧製造公開資料。

表 37-5 本章思考地圖

本章概念	關鍵提問	後續延伸閱讀
派工與負荷	瓶頸負荷多少？生產週期與交期如何取舍？	第 38 章
AMHS 與物流	搬運時間占生產週期多少？	第 38 章
追溯	出問題時要圍堵多少？追溯到哪一個粒度？	第 38 章
AI 製程最佳化	需要多少實驗？找到的參數驗證了嗎？	第 38 章
數位孿生與熱補償	模型在沒見過的條件下仍然有效嗎？	第 38 章
中小企業的路徑	第一步解決哪個痛點？效益如何量化？	第 38 章

本章概念	關鍵提問	後續延伸章節
新創的量產	從原型到量產還缺什麼？	第 38 章

章末小結

- 晶圓代工以虛擬晶圓廠提供客戶透明的服務，以 AMHS 與智慧派工管理可重入的製程。範例中，最早交期比先進先出縮短約 14% 的生產週期，急件優先讓急件的延遲比例降到 8%；但負荷的影響更大，瓶頸負荷從 78% 升到 99%，生產週期從 43.6 小時增加到 61.1 小時；每次搬運多 45 分鐘，生產週期增加約 22%。
- 封裝測試的智慧化從自動搬運走向資料與 AI。追溯的粒度決定圍堵範圍：範例中班別層級平均需圍堵約 1.1 萬顆，單顆層級只需約 3,700 顆。貝氏最佳化以 25 次實驗找到與 81 次格點實驗相當或更好的打線參數，但找到的參數仍須驗證。
- 電子製造以數位孿生「模擬先行」規劃產線，相關的成效數字多來自廠商的公開說法。工具機的熱變位補償以溫度預測熱變形：範例中誤差從約 55 μm 降到約 2.5 μm ；不含環境溫度的模型在夏天出現系統性偏移，說明模型要在沒見過的條件下驗證。
- 中小企業宜分階段導入：看得見、管得好、算得準、自己調。範例中單機聯網與停機通知把 OEE 從 72.0% 提高到 77.6%，閉環補償把良率提高到 99.1%，兩個階段各約 17~19 個月回收，但結果對假設很敏感。
- 新創的挑戰是從原型到量產：無人機強調零組件國產化與元件來源的證明，機器人把 AI 內建在產品中而需要模型的變更管理，積層製造則需要以製程監控與追溯證明每一次都印得一樣。

習題

一、選擇題

1. 讓客戶如同擁有自己的晶圓廠般取得進度與品質資訊的服務概念是？（A）虛擬晶圓廠 （B）燈塔工廠 （C）關燈工廠 （D）智慧機上盒

2. 晶圓廠中以天車自動搬運晶圓盒的系統是？(A) PLM (B) SPC (C) AMHS (D) ERP
3. 晶圓在製程中反覆回到同一組機台的特性稱為？(A) 可分割 (B) 可重入 (C) 可逆 (D) 可平行
4. 生產週期除以純加工時間的指標稱為？(A) OEE (B) Cpk (C) MTBF (D) X 因子
5. 依本章的模擬，對生產週期影響最大的是？(A) 瓶頸負荷 (B) 非瓶頸機台的台數 (C) ERP 的版本 (D) 報表的格式
6. 追溯粒度愈細，出問題時需圍堵的數量會？(A) 無法判斷 (B) 愈少 (C) 愈多 (D) 不變
7. 以代理模型與期望改善量選擇下一次實驗的方法是？(A) 格點搜尋 (B) 隨機猜測 (C) 先進先出 (D) 貝氏最佳化
8. 工具機加工精度最主要的誤差來源之一是？(A) 網路延遲 (B) 操作面板的語言 (C) 熱變形 (D) 切削液的顏色
9. 讓既有機台聯網、擷取狀態資料的裝置是？(A) SBOM (B) 智慧機上盒 (C) AMHS (D) CoWoS
10. 依本章，無人機新創打入國際市場常需證明的是？(A) 辦公室的坪數 (B) 公司的成立年數 (C) 關鍵元件的來源 (D) 網站的配色

二、簡答題

11. 說明虛擬晶圓廠的概念，以及它與製造服務化的關係。
12. 為什麼晶圓廠的派工比一般工廠困難？說明可重入流程與 AMHS 的影響。
13. 說明生產週期與瓶頸負荷的關係，以及晶圓廠為何保留產能餘裕。
14. 單顆追溯需要哪些條件？
15. 比較格點實驗與貝氏最佳化的優缺點。
16. 說明「模擬先行」的數位孿生在電子製造中的價值與限制。
17. 為什麼熱補償模型要在不同季節驗證？

18. 說明中小企業智慧化的四個階段與常見的陷阱。

三、計算題

19. 某瓶頸機台群有 3 台，每批晶圓需經過 4 次、每次平均 1.995 小時（含變異），投料間隔 3.0 小時，瓶頸負荷約為多少？

20. 某產品的純加工與搬運時間為 40 小時，平均生產週期 60 小時，X 因子為多少？

21. 班別層級追溯需圍堵 8,000 顆，單顆層級需圍堵 4,167 顆；若每顆的重新檢驗成本為 5 元，單顆追溯可節省多少檢驗成本？

22. 4 個參數各 3 個水準的全因子實驗需幾次？各 5 個水準需幾次？以 25 次的貝氏最佳化取代 3 水準格點實驗，實驗次數減少約多少百分比？

23. 某工具機 Z 軸的熱變位係數為每 $^{\circ}\text{C}$ $2.6\ \mu\text{m}$ ，前軸承溫升 8°C ，熱變位約為多少？

24. 稼動率 85%、性能 90%、良率 97%，OEE 為多少？

25. 某導入階段投資 150 萬元，每月效益 8.1 萬元，約幾個月回收？

26. 每月產量 30,000 件，報廢率從 3% 降到 0.9%，每件報廢損失 150 元，每月可節省多少？

四、申論與設計題

27. 選擇本章的一個產業，說明其主要痛點、智慧製造的做法，以及與本書各章的對應。

28. 評論以下說法：「中小企業應該等資金充足時，一次導入完整的智慧工廠。」

29. 為一家從原型走向量產的機器人新創，設計品質系統與追溯架構，並說明內建 AI 模型的變更管理。

五、是非題

30. 派工規則可以讓所有批次都同時變快。

31. 瓶頸負荷接近 100% 時，生產週期會急劇上升。

32. 單顆追溯只需要在產品上打標記即可。

33. 貝氏最佳化保證每次都找到全域最佳解。

34. 企業公開的成效數字，閱讀時應注意其計算基準。

35. 中小企業的智慧化宜從一個看得見效益的痛點開始。

六、進階挑戰題

36. 擴充 37.1 節的模擬：加入機台故障與預防保養（第 26 章）、設定切換時間，並以強化學習或基因演算法學習派工規則，與傳統規則比較。

37. 為一家封測廠設計追溯的資料模型：涵蓋晶圓、晶粒位置、基板條、材料批、機台、參數與測試結果，並以圖資料庫實作追溯查詢。

38. 整合 37.3 與 37.4 節：為一家工具機使用者設計從機台聯網、熱補償到閉環控制的完整方案，並估算效益與回收期。

七、補充題

39. 列出 37.4 節中小企業智慧化的四個階段。

40. 列出表 37-4 中新創的六項製造挑戰。

提示與參考解答

1. A。

2. C。

3. B。

4. D。

5. A。

6. B。

7. D。

8. C。

9. B。

10. C。

11. 參考：透過線上系統讓客戶查詢進度、良率與品質，並與晶圓廠協作，如同擁有自己的工廠；這是以資訊透明與服務提升價值的服務化實踐。
12. 參考：上千台機台、數百道工序，晶圓反覆使用同一組機台，各層的批次互相競爭；搬運時間與等待時間常大於加工時間，AMHS 的壅塞也會影響派工的效果。
13. 參考：負荷接近 100% 時等待時間急劇上升；保留餘裕可以換取較短而穩定的生產週期與交期。
14. 參考：每顆產品的唯一標記、材料更換時刻的精確記錄、上料時的條碼核對與防呆、機台與 MES 的整合、完整的資料模型。
15. 參考：格點實驗簡單、結果易解讀，但次數隨參數數量指數增加；貝氏最佳化次數少，但需要建模、對雜訊敏感、不保證每次更好，找到的參數仍須驗證。
16. 參考：在虛擬環境中規劃與驗證，減少試誤與擴建時間；限制在於模型的準確度與建置成本，公開的成效數字多來自廠商的說法。
17. 參考：訓練資料常只涵蓋某一季節的環境溫度，模型在沒見過的條件下可能出現系統性偏移；範例中不含環境溫度的模型在夏天最大誤差從 $2.5\ \mu\text{m}$ 增加到 $7.4\ \mu\text{m}$ 。
18. 參考：看得見、管得好、算得準、自己調；陷阱包括沒有人看資料、停機原因沒有人填、一次導入太多、過度依賴單一供應商、忽略資安。
19. $4 \times 1.995 \div (3 \times 3.0) = 7.98 \div 9 \approx 88.7\%$ 。
20. $60 \div 40 = 1.5$ 。
21. $(8,000 - 4,167) \times 5 = 19,165$ 元。
22. 81 次；625 次； $(81 - 25) \div 81 \approx 69\%$ 。
23. $2.6 \times 8 = 20.8\ \mu\text{m}$ 。
24. $0.85 \times 0.90 \times 0.97 \approx 74.2\%$ 。
25. $150 \div 8.1 \approx 18.5$ ，約 19 個月。
26. $30,000 \times (3\% - 0.9\%) = 630$ 件， $630 \times 150 = 94,500$ 元。
27. 參考：例如工具機使用者：痛點是稼動率與精度；做法是智慧機上盒、OEE、熱補償與刀具管

理；對應第 8、9、11、26 章。

28. 參考：不同意。一次到位的風險高、現場難以消化、效益難以驗證；分階段導入可以每一步驗證效益、累積能力與資料。

29. 參考：建立進料檢驗、製程 SPC、出貨測試與每台的序號追溯；記錄關鍵零組件、校正與測試資料；AI 模型以版本管理、驗證、核准與追溯，安全功能與 AI 分離。

30. 否，派工常是「誰先」的取捨。

31. 是。

32. 否，還需要精確記錄材料更換的時刻與系統整合。

33. 否。

34. 是。

35. 是。

36. 提示：故障與保養會改變瓶頸的有效產能；學習派工時應以多個隨機種子評估，避免過度擬合單一情境。

37. 提示：以節點表示晶圓、晶粒、材料批與產品，以邊表示「使用」「加工於」等關係，正向與反向追溯都是圖的走訪。

38. 提示：先以聯網找出停機與精度的主要損失，再決定熱補償與閉環的優先順序，並以 t_4 、 t_5 的方法估算效益。

39. 看得見、管得好、算得準、自己調。

40. 從原型到量產、品質系統從無到有、元件來源的證明、小量多樣的生產、內建 AI 的產品、資金與人力有限。

第 38 章

總整專題：學習工廠實作

編著 李世淵（機器人叫獸） | 助教 李天宇、李宇晴

本章重點

- 學習工廠的理念、場域與基準模型
- 企業出題：需求、KPI 與量測設計
- 數位主線、孿生與 AI 模組的架構
- PoC、試行檢定與專題時程
- 技術文件、展示、答辯與反思

叫獸開講：老闆的一句話

有一年的總整專題，一家做汽車零件的企業來出題。第一次會議，廠長講得很直接：「我們的 CNC 每天都在加班，可是出貨還是趕不上。你們能不能用 AI 幫我們排程？」學生們很興奮，回去就開始讀強化學習的論文。

兩週後，我請他們先做一件很「不 AI」的事：到現場量一個星期的資料。每一台機台什麼時候在做、什麼時候停、為什麼停，一件產品從投料到出貨要多久。量完之後，他們發現排程不是最大的問題——真正的瓶頸是一台 CNC，它每天有將近一個半小時在等刀具、等首件檢驗、等師傅來處理警報。排程演算法再好，也救不了一台三分之一時間在等待的瓶頸。

後來，這個團隊的專題變成了三件事：讓瓶頸機台的停機原因被即時記錄與通知；以數位孿生比較幾個改善方案的效益與成本；選出效益最好的刀具路徑最佳化與預測換刀，在學習工廠中試行，再到企業現場驗證。期末展示時，廠長最在意的不是用了什麼模型，而是學生拿出來的那張圖：試行前後各量了五週，良品產出的提升有信賴區間、有成本、有回收期。他說：「這是我第一次看到學生的專題，敢把『可能沒效』的情況也算進去。」

這一章是本書的最後一章，也是把前面三十七章的工具組合起來的一章。我們從學習工廠的教學理念與場域設計談起；說明如何從企業出題中定義需求、現況與 KPI；設計數位主線、數位孿生與 AI 模組的架構；開發 PoC、驗證並評估效益；最後談技術文件、公開展示、答辯與反思。

（說明：本節情境由作者綜合多年指導專題的經驗改寫，人物與細節已調整。）

學習目標

讀完本章後，你應該能夠：

1. 說明學習工廠的概念、發展與場域設計，並建立教學產線的基準模型。
2. 將企業的問題轉化為需求、現況與可量測的 KPI，並規劃足以證明改善的量測。
3. 設計包含數位主線、數位孿生與 AI 模組的系統架構，並以事件資料計算 KPI 與進行追溯。
4. 以數位孿生比較改善方案，並以試行資料的統計檢定評估效益。

5. 以要徑法規劃專題時程，管理量測與開發的相依性。
6. 撰寫技術文件、進行公開展示與答辯，並反思專題的限制與後續。

核心概念

表 38-1 本章核心名詞中英對照

中文名詞	英文	一句話說明
學習工廠	Learning Factory	以真實的製程與產品進行教學與研究的工廠環境
總整專題	Capstone Project	整合所學、解決真實問題的專題
企業出題	Industry-sponsored Project	由企業提供真實問題與場域的專題
關鍵績效指標	Key Performance Indicator, KPI	衡量目標達成程度的量化指標
基準	Baseline	改善前的現況量測，作為比較的依據
數位主線	Digital Thread	串接產品與製程全生命週期資料的資料鏈
概念驗證	Proof of Concept, PoC	以小規模的實作驗證想法的可行性與效益
試行	Pilot	在實際場域中以有限範圍運行新方案
信賴區間	Confidence Interval	估計值的不確定範圍
要徑	Critical Path	決定專案完成時間的工作序列
檢定力	Statistical Power	在改善確實存在時能檢定出來的機率
反思	Reflection	回顧專題的過程、決策與學習

38.1 學習工廠的教學理念與場域設計

38.1.1 學習工廠的概念與發展

學習工廠 (learning factory) 是以真實的製程、真實的產品與接近真實的價值鏈，進行教學、訓練與研究的工廠環境。「學習工廠」一詞在 1994 年出現於美國：美國國家科學基金會 (NSF) 與高等研究計畫署 (ARPA) 支持「製造工程教育夥伴」計畫，由賓州州立大學、波多黎各大學馬亞圭斯分校、華盛頓大學與桑迪亞國家實驗室，結合數十家企業組成；賓州州立大學建立了約 2,000 平方

公尺的場域，讓跨領域的學生團隊與企業合作，解決真實的設計問題。這項計畫的創始者於 2006 年獲得美國國家工程學院的戈登獎 (Gordon Prize)，表彰其在工程教育上的創新。在歐洲，德國達姆施塔特工業大學於 2007 年設立以精實生產為主題的「流程學習工廠 CiP」；2011 年 5 月，「歐洲學習工廠倡議」(IELF) 成立，第一屆學習工廠研討會也在達姆施塔特工業大學舉行；2017 年更名為「國際學習工廠協會」(IALF)。國際生產工程學會 (CIRP) 對學習工廠的定義強調幾個要素：真實的流程、可變更的場域、類似真實價值鏈的環境、實體產品的製造，以及讓學習者主動參與的教學設計。

學習工廠的教學理念是「做中學」：學生不是聽完精實生產、OEE 或數位孿生的課就結束，而是在一條真實的產線上量測、分析、改善，並承擔改善不如預期的後果。這與本書一再強調的「智慧製造是系統工程」相呼應：真正的困難往往不在單一技術，而在資料、設備、流程與人的整合。

38.1.2 場域設計

一個學習工廠的場域，可以從小規模開始。本章的範例是一條五站的教學產線：上料、CNC 加工、機械手臂組裝、視覺檢測與包裝，站間有小型的緩衝區；所有設備透過 OPC UA 或 MQTT 聯網 (第 11 章)，事件與量測資料進入時序資料庫與 MES (第 17、23 章)，並在數位孿生 (第 19~21 章) 中同步呈現。場域的設計應考慮幾個原則：產品要夠簡單，讓學生能在一學期內理解全貌，但又要足夠的變異 (如多個品項、可調的參數)；設備要開放，允許學生讀取資料、修改程式與參數；安全要先行，機器人與 CNC 的安全功能與教學功能分離 (第 30 章)；網路要分區，教學網路與設備控制網路之間有受控的通道 (第 35 章)。




圖 38-1 學習工廠的五站教學產線與資料層

表 38-2 學習工廠的設備、資料與對應章節

站別	設備	擷取的資料	本書相關章節
上料	料架、條碼掃描、AMR	物料批號、上料時間	第 10、20 章
CNC 加工	CNC、主軸振動感測、刀具管理	加工時間、主軸負載、振動、刀具壽命	第 9、26 章
手臂組裝	協作型機械手臂、力感測	組裝時間、力量曲線、異常	第 10、30 章
視覺檢測	工業相機、AI 檢測模型	影像、判定、信心值	第 24、25 章
包裝	秤重、標籤列印	重量、序號、出貨紀錄	第 17、33 章
整線	MES、數位孿生、儀表板	工單、事件、KPI	第 17、19、23 章

38.1.3 範例：教學產線的基準模型

在動手改善之前，先建立產線的基準模型。下面的程式以串列產線的遞迴式，計算每一件在各站的開始與離開時間：當下游緩衝區滿了，上游站即使做完也必須等待（阻塞）。工時以伽瑪分布描述變異，並加入小停機與 CNC 加工的不良：

```
import numpy as np
# 學習工廠的基準模型：一條五站的教學產線（上料、CNC 加工、機械手臂組裝、視覺檢測、包裝），站間有有限緩衝。以串列產線的遞迴式計算每件的開始與離開時間（含阻塞），得出產出、生產週期、在製品、各站稼動與良率，作為專題的基準（baseline）
STATIONS = ["上料", "CNC 加工", "手臂組裝", "視覺檢測", "包裝"]
MEAN = np.array([40, 95, 80, 45, 50.0]) # 平均工時（秒）
```

```

CV = np.array([0.15, 0.10, 0.25, 0.10, 0.20])      # 工時的變異係數
FAIL = np.array([0.0, 0.02, 0.03, 0.01, 0.0])      # 每件發生小停機的機率
REPAIR = np.array([0, 600, 300, 240, 0.0])         # 小停機的平均修復時間(秒)
def simulate(n=1500, mean=MEAN, buf=(2, 2, 2, 2), defect=0.04, fail=FAIL, seed=0):
    r = np.random.default_rng(seed); k = len(mean)
    p = r.gamma(1 / CV ** 2, mean * CV ** 2, (n, k)) # 工時：伽瑪
分布
    p += (r.random((n, k)) < fail) * r.exponential(np.maximum(REPAIR, 1e-9), (n, k))
    S = np.zeros((k, n)); D = np.zeros((k, n))
    for j in range(n):
        for i in range(k):
            S[i, j] = max(D[i - 1, j] if i else 0, D[i, j - 1] if j else 0)
            c = S[i, j] + p[j, i]
            jb = j - buf[i] - 1 if i < k - 1 else -1 # 下游緩衝滿
時阻塞
            D[i, j] = max(c, S[i + 1, jb]) if i < k - 1 and jb >= 0 else c
        warm = n // 5; T = D[-1, -1] - D[-1, warm]
        good = r.random(n) > defect # CNC 加工
的不良，在視覺檢測站剔除
        thr = (n - 1 - warm) / T * 3600; lt = np.mean(D[-1, warm:] - S[0, warm:])
        util = p[warm:].sum(0) / (D[:, -1] - D[:, warm])
        return {"產出(件/小時)": thr, "良品產出(件/小時)": thr * good[warm:].mean(), "生產週期(秒)": lt,
            "在製品(件)": thr / 3600 * lt, "各站負荷": util, "良率": good[warm:].mean(),
            "_S": S, "_D": D, "_good": good}
k = simulate()
for name in ["產出(件/小時)", "良品產出(件/小時)", "生產週期(秒)", "在製品(件)", "良率"]:
```

```

    print(f"{name}: {k[name]:.3f}" if name == "良率" else f"{name}: {k[name]:.1f}")
print("各站負荷: " + "、".join(f"{s} {u:.0%}" for s, u in zip(STATIONS, k["各站負荷"])))
print(f"瓶頸: {STATIONS[int(np.argmax(k['各站負荷']))]}: 理論上限(只看 CNC 平均工時){3600 / MEAN[1]:.1f} 件/小時")

```

執行結果：穩態下產線每小時產出約 33.5 件，良品約 31.7 件，良率約 94.6%；平均生產週期約 786 秒，在製品約 7.3 件。各站負荷為上料 37%、CNC 加工 98%、手臂組裝 82%、視覺檢測 44%、包裝 47%，瓶頸是 CNC 加工；只看 CNC 平均工時的理論上限為每小時 37.9 件。



圖 38-2 教學產線各站的負荷：CNC 加工是瓶頸

基準模型告訴我們三件事。第一，瓶頸在 CNC：它的負荷（含小停機）接近 100%，其他站的改善不會提高產出（第 8 章的限制理論）。第二，實際產出（33.5）低於只看平均工時的上限（37.9），差距來自小停機、工時變異與阻塞——這正是改善的空間。第三，在製品與生產週期符合利特爾法則（在製品 = 產出率 × 生產週期）： $33.5 \div 3,600 \times 786 \approx 7.3$ 件。這個模型會成為後面數位孿生的核心。

38.2 企業出題：需求、現況與 KPI 定義

38.2.1 從問題到需求

企業出題時，問題常以「解法」的形式出現：「幫我們導入 AI 排程」「做一個數位孿生」「建一個儀表板」。專題的第一步，是把解法還原成問題：為什麼需要 AI 排程？是因為交期延遲、加班太多，還是換線太頻繁？問題的根源在哪裡？這需要訪談不同的角色——廠長、生管、現場主管、作業員、資訊人員——並到現場觀察（第 8 章的現場走動）。

需求的整理可以用三個問題：誰的痛點（使用者是誰）、痛點的代價（每月損失多少時間或金錢）、成功的樣子（改善到什麼程度算成功）。需求文件也應寫下「不做什麼」：專題只有一學期，範圍必須聚焦。

38.2.2 KPI 的定義

KPI 要能量測、與目標對應、有明確的定義與資料來源。「提升效率」不是 KPI；「CNC 瓶頸站每小時良品產出，由 MES 的包裝站完工紀錄計算，扣除前 20% 的暖機時段」才是。好的 KPI 定義包括：名稱、計算公式、資料來源、量測頻率、基準值、目標值與負責人。也要注意指標之間的取舍：只看產出可能犧牲品質，只看 OEE 可能鼓勵過量生產（第 8 章）。因此常以一個主要 KPI 搭配幾個「護欄指標」（如良率、生產週期、加班時數）。

表 38-3 KPI 定義範例

項目	主要 KPI	護欄指標
名稱	每小時良品產出	良率、生產週期、在製品
公式	包裝站良品數 ÷ 運轉時數	良品數 ÷ 總數；完工時間 - 投料時間

項目	主要 KPI	護欄指標
資料來源	MES 完工與品質紀錄	MES 事件紀錄
量測頻率	每日	每日
基準值	試行前量測	試行前量測
目標值	提升 8% 以上	良率不低於基準；生產週期不增加
負責人	專題組長	品保聯絡人

38.2.3 範例：需要量測幾天？

有了 KPI，接著要量測現況。一個常被忽略的問題是：產線每天的表現都在波動，量幾天才夠？如果改善的效果比每天的波動還小，量太少天就無法分辨「真的改善」與「剛好運氣好」。下面的程式以基準模型模擬每天約 4 小時的運轉，估計日間的波動，並計算證明不同程度的改善所需的天數：

```
import numpy as np
from scipy import stats
# KPI 的基準量測：企業出題後，先量測現況。學習工廠每天實際運轉約 4 小時，每天良品產出會隨停機與
# 工時變異而波動。要證明改善「至少 8%」，基準與試行各需要量測幾天？
# 延續 38.1.3 節基準模型的程式
def daily(days, seed0=100, **kw):
    return np.array([simulate(n=140, seed=seed0 + d, **kw)["良品產出 (件/小時)"] for d in
range(days)])
def days_needed(sd, delta, alpha=0.05, power=0.8):
    # 兩樣本 t 檢定的近似
    # 樣本數
    z = stats.norm.ppf(1 - alpha / 2) + stats.norm.ppf(power); return int(np.ceil(2 * (z
* sd / delta) ** 2))
base = daily(20); m, sd = base.mean(), base.std(ddof=1)
print(f"基準 20 天：良品產出平均 {m:.1f} 件/小時，日間標準差 {sd:.1f} (變異係數 {sd /
m:.0%})，最低 {base.min():.1f}、最高 {base.max():.1f}")
for imp in [0.05, 0.08, 0.15]:
    print(f"要偵測 {imp:.0%} 的改善 ({m * imp:.1f} 件/小時)：基準與試行各約需
{days_needed(sd, m * imp)} 天")
lo, hi = stats.t.interval(0.95, len(base) - 1, m, sd / np.sqrt(len(base)))
print(f"只量 3 天的風險：3 天平均的 95% 範圍約 ±{stats.t.ppf(0.975, 2) * sd /
np.sqrt(3):.1f} 件/小時；20 天的平均信賴區間 {lo:.1f}~{hi:.1f}")
```

執行結果：20 天的基準量測中，良品產出平均約 31.8 件 / 小時，日間標準差約 3.2 (變異係數約 10%)，最低 23.5、最高 36.8。要以 95% 的信心水準與 80% 的檢定力偵測 5% 的改善，基準與試行各約需 64 天；8% 的改善約需 25 天；15% 的改善約需 8 天。若只量 3 天，3 天平均的 95% 範圍約為 ±8.0 件 / 小時；20 天的平均信賴區間則為 30.4 ~ 33.3。




圖 38-3 日間波動與所需量測天數：改善愈小，需要量測愈久

這個結果對專題的規劃影響很大。一學期只有十幾週，若預期的改善只有 5%，就不可能在學習工廠中以統計方法證明；這時應該選擇效果更大的方案、降低日間的波動（例如固定品項、排除已知的干擾），或改用更敏感的指標（例如直接量測 CNC 的單件工時）。只量三天就宣稱「產出提升 10%」，很可能只是波動。

38.3 架構設計：數位主線、學生與 AI 模組

38.3.1 分層的系統架構

專題的系統架構可以沿用本書的分層：設備與感測層（第 7、9、10 章）、通訊與邊緣層（第 11 章）、資料與數位主線層（第 20、23 章）、數位學生與模擬層（第 19~21 章）、AI 與分析層（第 22~27 章），以及應用與人機介面層（第 28~31 章）；資安（第 35 章）與治理（第 36 章）則貫穿所有層。架構設計的重點不是把每一層都做滿，而是讓專題的關鍵路徑——從資料、模型到決策與行動——完整而可驗證。



圖 38-4 總整專題的系統架構：數位主線串接設備、學生、AI 與應用

表 38-4 架構各層的設計決策

層	設計決策	常見的選擇	本書相關章節
設備與感測	擷取哪些訊號？取樣頻率？	控制器資料、外加感測器	第 7、9、10 章
通訊與邊緣	協定與邊緣處理	OPC UA、MQTT、邊緣閘道	第 11 章
數位主線	資料模型與識別碼	序號、工單、物料批、事件	第 20、23 章
數位學生	模型的粒度與同步	離散事件模擬、物理模型	第 19~21 章
AI 模組	預測、檢測或最佳化？	監督式學習、最佳化、代理	第 22~29 章
應用與介面	誰在什麼時候做什麼決策？	儀表板、通知、對話介面	第 28~31 章
資安與治理	存取控制、模型核准	分區、模型卡、變更管理	第 35、36 章

38.3.2 數位主線：從事件到 KPI 與追溯

數位主線的核心是一致的識別碼與事件紀錄：每一件產品有序號，每一個事件記錄「哪一件、在哪一站、何時開始與結束、用了什麼料、結果如何」。有了這樣的資料，KPI 可以由事件直接計算，而不是靠人工填報；追溯也只是資料的查詢。下面的程式把基準模型的結果轉成事件紀錄，計算 KPI，並回答一個追溯問題：

```
import numpy as np, json
from collections import Counter
# 數位主線：把工單、物料批、各站事件與品質結果串成一條可查詢的資料鏈。由事件紀錄直接計算 KPI，並回
```

答一個追溯問題：CNC 主軸在某段時間振動異常，哪些已出貨的產品受影響？

延續 38.1.3 節基準模型的程式

```
k = simulate(n=300, seed=5); S, D, good = k["_S"], k["_D"], k["_good"]
events, units = [], []
for j in range(S.shape[1]):
    uid = f"U{j:04d}"; wo = f"WO-{j // 50 + 1:02d}"; lot = f"AL-{j // 120 + 1}" # 每
50 件一張工單、每 120 件一批鋁料
    units.append({"序號": uid, "工單": wo, "鋁料批": lot, "判定": "良品" if good[j] else "不
良", "出貨": bool(good[j])})
    for i, st in enumerate(STATIONS):
        events.append({"序號": uid, "站別": st, "開始": round(S[i, j], 1), "結束":
round(D[i, j], 1)})
def trace(station, t0, t1): # 正向追溯：某站在某時段加工的件，現在在哪裡、
是否已出貨
    hit = {e["序號"] for e in events if e["站別"] == station and e["開始"] < t1 and e["結束"] > t0}
    return [u for u in units if u["序號"] in hit]
print(f"事件紀錄 {len(events):,} 筆、產品 {len(units)} 件；範例：{json.dumps(events[7],
ensure_ascii=False)}")
done = [e for e in events if e["站別"] == "包裝"]; T = (done[-1]["結束"] - done[59]["結束"]) / 3600
print(f"由事件計算：第 61~300 件的產出 {(len(done) - 60) / T:.1f} 件／小時，良率
{np.mean([u['判定'] == '良品' for u in units[60:]]:.1%}")
hits = trace("CNC 加工", 9000, 12600) # 假設 CNC 主軸在第 2.5~3.5 小時振動異常
c = Counter((u["工單"], u["出貨"]) for u in hits)
print(f"CNC 在 9,000~12,600 秒加工的產品 {len(hits)} 件，序號 {hits[0]['序號']}~{hits[-1]['序號']}；其中已判良品出貨 {sum(u['出貨'] for u in hits)} 件，分屬工單：" + "、".join(sorted({u['工單'] for u in hits})))
print(f"涉及鋁料批：{'、'.join(sorted({u['鋁料批'] for u in hits})))}（反向追溯：可再查同批鋁料的其他產品）")
```

執行結果：300 件產品共產生 1,500 筆事件紀錄，每筆包含序號、站別、開始與結束時間。由事件計算第 61~300 件的產出約 35.1 件 / 小時、良率約 97.9%（這是一次較短的模擬，與 t1 的長期估計不同，也提醒我們短期資料的波動）。假設 CNC 主軸在 9,000~12,600 秒之間振動異常，追溯查詢找出這段時間在 CNC 加工的 38 件產品，序號 U0074~U0111，全部已判為良品出貨，分屬工單 WO-02 與 WO-03，使用的鋁料批為 AL-1。

這個查詢在有數位主線時只需幾秒；沒有數位主線時，可能要翻閱紙本工單、比對機台的紀錄與出貨單，花上好幾天，而且只能追溯到工單層級（第 37 章的追溯粒度）。38 件全部被視覺檢測判為良品，也提醒了另一件事：主軸振動造成的可能是視覺看不到的問題（如尺寸或內部應力），需要額外的抽樣量測來判斷是否要通知客戶。

38.3.3 AI 模組的選擇

AI 模組應該從問題出發，而不是從技術出發。若瓶頸是 CNC 的小停機，可能需要的是預測維護

(第 26 章)；若瓶頸是加工時間，可能是製程參數或刀具路徑的最佳化(第 25、37 章)；若問題是漏檢，才需要更好的視覺模型(第 24 章)；若問題是現場人員找不到資料，生成式 AI 的知識助理可能最有幫助(第 28 章)。每一個 AI 模組都應有模型卡、驗收標準與負責人(第 36 章)，並在架構中明確它的輸入、輸出與失效時的備援。

38.4 PoC 開發、驗證與效益評估

38.4.1 先在學生中比較，再到現場試行

概念驗證 (PoC) 的目的，是以最小的成本驗證「這個方案值得做」。在學習工廠中，一個好的做法是：先在數位學生中比較多個方案的效益與成本，選出最有希望的一兩個；再到學習工廠試行，以真實資料檢定效益；最後才到企業現場驗證。數位學生讓我們能在一天內比較十個方案，但它的結論取決於模型的假設——所以試行是必要的。

38.4.2 範例：方案比較與試行檢定

下面的程式在基準模型中比較五個方案：加大緩衝、CNC 預測維護(小停機減少六成)、CNC 刀具路徑最佳化(加工時間縮短 12%)、視覺檢測回饋(不良率減半)，以及預測維護加刀具路徑最佳化；再選擇 C 方案在學習工廠試行 25 天，與 25 天的基準比較：

```
import numpy as np
from scipy import stats
# PoC 與效益評估：先在數位學生 (t1 的模型) 中比較改善方案，再選一案在學習工廠試行，以基準與試行各
25 天的資料檢定改善是否成立
# 延續 38.2.3 節每日量測的程式 (其中已包含基準模型)
OPTIONS = { # 方案：(模型參數的修改、成本 萬元)
    "基準": ({}, 0),
    "A 加大緩衝": ({ "buf": (4, 4, 4, 4)}, 8),
    "B CNC 預測維護": ({ "fail": FAIL * np.array([1, 0.4, 1, 1, 1])}, 25),
    "C CNC 刀具路徑最佳化": ({ "mean": MEAN * np.array([1, 0.88, 1, 1, 1])}, 15),
    "D 視覺檢測回饋 (不良率減半)": ({ "defect": 0.02}, 20),
    "B+C": ({ "fail": FAIL * np.array([1, 0.4, 1, 1, 1]), "mean": MEAN * np.array([1,
0.88, 1, 1, 1])}, 40)}
def twin(kw, reps=8): return np.mean([simulate(seed=s, **kw)["良品產出 (件/小時)"] for s
in range(reps)])
b = twin({})
for name, (kw, cost) in OPTIONS.items():
    v = twin(kw); gain = v / b - 1
    extra = f"，每萬元提升 {gain * 100 / cost:.2f} 個百分點" if cost else ""
    print(f"{name}: 良品產出 {v:.1f} 件/小時 ({gain:+.1%})，成本 {cost} 萬元{extra}")
base, pilot = daily(25, seed=300), daily(25, seed=400, **OPTIONS["C CNC 刀具路徑最佳化
"][0]) # 試行：C 方案
```

```
t, p = stats.ttest_ind(pilot, base, equal_var=False); d = pilot.mean() - base.mean()
se = np.sqrt(pilot.var(ddof=1) / 25 + base.var(ddof=1) / 25)
print(f"試行 C 方案 25 天：{pilot.mean():.1f} 對基準 {base.mean():.1f} 件／小時，差 {d:.1f}
({d / base.mean():+.1%})，95% 信賴區間 {d - 1.96 * se:.1f}~{d + 1.96 * se:.1f}，p =
{p:.3f}")
```

執行結果：在學生中（8 次模擬平均），基準的良品產出約 31.1 件／小時。A 加大緩衝提升約 1.7%（成本 8 萬元）；B CNC 預測維護提升約 6.0%（25 萬元）；C 刀具路徑最佳化提升約 8.7%（15 萬元），每萬元提升約 0.58 個百分點，是成本效益最好的單一方案；D 視覺檢測回饋提升約 2.3%（20 萬元）；B+C 合計提升約 15.4%（40 萬元）。試行 C 方案 25 天的良品產出平均約 35.1 件／小時，基準約 30.8，差 4.3（約 +14.1%），95% 信賴區間 2.4~6.3， $p < 0.001$ 。




圖 38-5 數位學生中的方案比較，以及試行的效益與信賴區間

這個結果值得仔細解讀。第一，方案的效果與瓶頸有關：加大緩衝與改善視覺檢測，都不是處理瓶頸本身，所以效果有限；直接改善瓶頸的 B 與 C 效果最大。第二，試行的點估計（約 +14%）高於學生的預測（約 +8.7%），但信賴區間 2.4~6.3 件／小時涵蓋了學生預測的約 2.7 件／小時。正確的結論是「改善確實存在，幅度約在 8%~20% 之間」，而不是「改善了 14%」。報告效益時，應同時呈現點估計與信賴區間，並說明學生預測與試行結果的差異。第三，效益評估最後要換算成企業在意的語言：每月多出的良品、節省的加班、投資與回收期（第 37 章的 t_5 ）。

38.4.3 範例：專題時程的要徑

前面的分析指出，基準與試行各需約 25 個運轉天。若學習工廠每週運轉 5 天，各需 5 週——這在一學期 18 週的專題中佔了很大的比例。下面的程式以要徑法分析專題的時程：

```
import networkx as nx
# 專題時程的要徑分析：一個學期 18 週。基準量測與試行各需約 25 個運轉天（ $t_2$ ），若每週運轉 5 天，各需 5 週。以要徑法找出決定完成時間的工作；基準量測與架構設計、學生建模並行
TASKS = { # 工作：（週數，前置工作）
```

```

"企業訪談與出題": (1, []), "KPI 定義與量測規劃": (1, ["企業訪談與出題"]),
"基準量測": (5, ["KPI 定義與量測規劃"]), "架構設計": (2, ["KPI 定義與量測規劃"]),
"數位孿生建模": (2, ["架構設計"]), "方案比較": (1, ["數位孿生建模", "基準量測"]),
"PoC 開發": (3, ["方案比較"]), "試行與量測": (5, ["PoC 開發"]),
"效益評估": (1, ["試行與量測"]), "技術文件": (2, ["PoC 開發"]),
"公開展示與答辯": (1, ["效益評估", "技術文件"])
def cpm(tasks):
    G = nx.DiGraph()
    for t, (d, pre) in tasks.items():
        G.add_node(t, d=d); G.add_edges_from((p, t) for p in pre)
    es = {}
    for t in nx.topological_sort(G): es[t] = max((es[p] + G.nodes[p]["d"] for p in
G.predecessors(t)), default=0)
    end = max(es[t] + G.nodes[t]["d"] for t in G); ls = {}
    for t in reversed(list(nx.topological_sort(G))):
        ls[t] = min((ls[s] for s in G.successors(t)), default=end) - G.nodes[t]["d"]
    return end, es, {t: ls[t] - es[t] for t in G}
end, es, slack = cpm(TASKS)
print(f"總工期 {end} 週 (學期 18 週) ; 要徑: " + " → ".join(sorted((t for t in es if
slack[t] == 0), key=es.get)))
print("有寬裕時間的工作: " + "、".join(f"{t} ({s} 週)" for t, s in slack.items() if s > 0))
t2 = dict(TASKS); t2["試行與量測"] = (3, ["PoC 開發"])      # 若試行只做 3 週 (15 天)
z, sd, m = 1.96 + 0.84, 3.2, 31.8                          # t2 的日間標準差與平均
print(f"試行縮短為 3 週: 總工期 {cpm(t2)[0]} 週, 但試行只有 15 天 (基準 25 天) 時, 只能可靠偵測
約 {z * sd * (1 / 25 + 1 / 15) ** 0.5 / m:.1%} 以上的改善 (各 25 天約 {z * sd * (2 / 25) **
0.5 / m:.1%})")

```

執行結果：總工期為 18 週，恰好等於一學期。要徑是企業訪談與出題 → KPI 定義與量測規劃 → 基準量測 → 方案比較 → PoC 開發 → 試行與量測 → 效益評估 → 公開展示與答辯；架構設計與數位孿生建模各有 1 週寬裕，技術文件有 4 週寬裕。若把試行縮短為 3 週，總工期可降為 16 週，但試行只有 15 天 (基準 25 天) 時，只能可靠偵測約 9.2% 以上的改善 (各 25 天約 8.0%)。




圖 38-6 總整專題的時程與要徑

要徑分析的啟示是：量測，而不是程式，決定了專題的完成時間。所以 KPI 的定義與量測規劃必須在第二週完成，基準量測要儘早開始，並與架構設計、孿生建模並行；技術文件有寬裕，但不應拖

到最後——它應該隨著開發逐步累積。專題的進度管理可以沿用第 27 章的排程觀念與第 36 章的變更管理：每週檢視要徑上的工作是否落後，範圍的變更要經過討論與記錄。

38.5 技術文件、公開展示、答辯與反思

38.5.1 技術文件

技術文件的讀者有三種：企業的決策者（要知道效益、成本與風險）、接手的工程師（要能重現與維護）、未來的學弟妹（要能在你的基礎上繼續）。一份完整的專題技術文件包括：問題與需求、現況與 KPI 的基準、系統架構與設計決策（以及為什麼不選其他方案）、資料的來源與定義、模型與演算法（含模型卡，第 36 章）、PoC 的實作、試行的方法與結果（含信賴區間與限制）、效益與成本、操作與維護手冊、已知問題與後續建議。

可重現性是技術文件的核心：程式碼放在版本控制系統中，註明套件版本；資料有資料卡，說明來源與處理方式；每一張圖與每一個數字，都能由文件中的程式重新產生。本書每一章的範例程式，都遵循這個原則；相關範例程式將於本書的實驗倉庫中維護。

表 38-5 專題成果與檢核重點

成果	檢核重點	本書相關章節
需求與 KPI 文件	問題是否還原？KPI 是否可量測？基準是否足夠？	第 8 章、38.2 節
架構文件	設計決策與替代方案是否說明？資安與治理是否納入？	第 35、36 章、38.3 節
程式與資料	能否重現？版本與資料來源是否記錄？	第 22、23 章
試行報告	是否呈現信賴區間與限制？孿生預測與試行是否比較？	第 25 章、38.4 節
效益評估	是否換算成企業的语言？成本與回收期是否合理？	第 32、37 章
展示與答辯	是否在時間內講清楚問題、方法、結果與限制？	38.5 節

38.5.2 公開展示與答辯

公開展示的聽眾通常很多元：企業主管、老師、同學與其他企業的訪客。好的展示從問題開始，而不是從技術開始：「這條產線的瓶頸每天有一個半小時在等待」比「我們使用了 XGBoost」更能抓

住聽眾。展示的結構可以是：問題與代價、現況與基準、方案與為什麼選它、試行的結果（含不確定性）、效益與成本、限制與下一步。現場示範應有備案：網路斷線、設備故障或模型出錯時，要有錄影或離線的版本。

答辯時，常見的問題包括：「你怎麼知道改善不是運氣？」（回答：試行天數、信賴區間與檢定）「如果換一個產品還有效嗎？」（回答：模型的適用範圍與重新驗證的機制）「出錯時誰負責？」（回答：負責人、核准流程與安全功能的分離）「企業要投資多少？多久回收？」（回答：成本、效益與敏感度分析）。誠實地說「我們不知道」或「這是我們的限制」，比含糊帶過更有說服力。

38.5.3 反思

專題的最後一步是反思：我們原本以為的問題，和真正的問題一樣嗎？哪一個決策是對的，哪一個如果重來會改變？數位孿生的預測與試行結果差多少，為什麼？團隊的分工與溝通有什麼可以改進？反思不是自我批判，而是把經驗轉成可遷移的能力。許多學生在反思中寫到的最大收穫，不是某一個演算法，而是「先量測再說」「問題比解法重要」「承認不確定性」這些態度。

38.5.4 全書結語

本書從智慧製造的定義與台灣的產業脈絡出發，走過感測、通訊、數位孿生、MES、精實生產、設計與製造技術、資料科學與工業 AI、企業 AI 與代理、Physical AI、服務化與供應鏈、永續製造、資安、治理與台灣的案例，最後回到一條學習工廠的產線。如果要用一句話總結這三十八章，那就是：智慧製造不是買一套系統，而是建立一個持續「量測、理解、決策、行動、再量測」的循環——技術讓這個循環更快、更準、更廣，而人決定這個循環往哪裡走。

希望讀者在合上書之後，能走進一座工廠，看見那些等待的時間、隱藏的變異與沒有被記錄的經驗，並且知道從哪裡開始。

案例

案例 38-1 教學情境：老闆的一句話

這是本章開頭的情境。企業要求「用 AI 排程」，學生先量測現場後發現真正的瓶頸是 CNC 的等待；專題轉為停機記錄、學生比較與刀具路徑最佳化，並以試行資料的信賴區間呈現效益。

啟示：先量測再說；把解法還原成問題。

案例 38-2 國際：學習工廠的發展

「學習工廠」一詞 1994 年出現於美國，NSF 與 ARPA 支持賓州州立大學、波多黎各大學馬亞圭斯分校、華盛頓大學與桑迪亞國家實驗室組成的夥伴計畫，讓學生團隊與企業合作解決真實問題，創始者並於 2006 年獲得戈登獎；德國達姆施塔特工業大學於 2007 年設立流程學習工廠 CiP；2011 年歐洲學習工廠倡議成立，2017 年更名為國際學習工廠協會。學習工廠從精實生產的訓練，逐步擴展到工業 4.0、數位孿生與 AI。

啟示：學習工廠是讓理論與實作對話的場域，也是產學合作的介面。

案例 38-3 教學情境：三天的「改善」

某專題團隊在試行三天後，發現產出提升約 10%，準備宣布成功。指導老師請他們再量兩週，結果改善縮小到約 3%，且信賴區間包含零。原來試行的那三天剛好排了工時較短的品項。團隊把這段經過寫進報告，並重新設計量測：固定品項、延長試行，並以單件工時作為輔助指標。

啟示：日間的波動可能比改善還大；量測設計是專題的一部分。

案例 38-4 教學情境：被否決的方案

另一個團隊花了六週開發視覺檢測的深度學習模型，準確率很高，但學生比較顯示，產線的瓶頸在 CNC，改善檢測對良品產出的貢獻很小。團隊在期中調整方向，把模型保留為品質改善的子題，主力轉向瓶頸。答辯時，評審最欣賞的正是這段「放棄」的決策過程。

啟示：好的方案不一定是技術最難的方案，而是解決瓶頸的方案。

案例 38-5 產學：從學習工廠到企業現場

學習工廠的試行成功後，團隊到企業現場進行為期四週的驗證。現場的品項更多、干擾更多，改善幅度比學習工廠小，但仍然顯著；企業決定在兩台瓶頸機台上正式導入，並由企業的工程師接手維護。團隊留下的技術文件與可重現的程式，讓交接只花了兩次會議。

啟示：學習工廠降低了試錯的成本，技術文件決定了成果能否延續。

案例 38-6 教學情境：反思報告中的一句話

一位學生在反思報告中寫道：「我原本以為智慧製造的重點是 AI，做完才知道，最難的是讓每個人相信同一份資料。」他的團隊花了最多時間的，是統一停機原因的代碼，以及讓現場人員願意即時記錄。

啟示：資料的一致與人的參與，是智慧製造最基礎也最困難的部分。

實作活動

活動 38-1 學習工廠的基準模型

修改 38.1 節的基準模型，使其符合你所在場域（或老師提供的情境）的站別、工時、停機與緩衝，並以實際量測的資料校正模型，比較模型與實際的產出、生產週期與在製品。

活動 38-2 KPI 與量測計畫

為企業出題撰寫需求文件與 KPI 定義（表 38-3 的格式），估計日間的波動，並以 38.2 節的方法計算基準與試行所需的天數。

活動 38-3 數位主線的資料模型

設計專題的資料模型：序號、工單、物料批、站別事件、品質結果與設備狀態，並實作由事件計算 KPI 與正反向追溯的查詢。

活動 38-4 學生比較與試行

在數位學生中比較至少三個改善方案的效益與成本，選擇一個在學習工廠試行，並以信賴區間與檢定呈現結果，說明學生預測與試行結果的差異。

活動 38-5 專題時程與風險

以要徑法規劃專題的時程，找出要徑與寬裕，並建立專題的風險登錄（第 36 章）：哪些風險可能讓專題延遲或失敗？如何因應？

活動 38-6 技術文件、展示與反思

依表 38-5 完成技術文件，準備 10 分鐘的公開展示與 10 分鐘的答辯，並撰寫一頁的反思報告。

延伸閱讀

- Eberhard Abele、Joachim Metternich、Michael Tisch，〈《Learning Factories: Concepts, Guidelines, Best-Practice Examples》〉，Springer，2019。
- Eberhard Abele 等，〈Learning factories for future oriented research and education in manufacturing〉，CIRP Annals，66(2)，2017。
- Wallace J. Hopp、Mark L. Spearman，〈《Factory Physics》〉，第 3 版，Waveland Press，2008。
- Douglas C. Montgomery，〈《Design and Analysis of Experiments》〉，Wiley。
- 國際學習工廠協會（IALF）的研討會論文集。

表 38-6 本章思考地圖

本章概念	關鍵提問	回顧的章節
學習工廠	場域能讓學生量測、修改與承擔後果嗎？	第 1、8 章
需求與 KPI	問題還原了嗎？KPI 可量測、有基準嗎？	第 8、25 章
量測設計	量測天數足以證明改善嗎？	第 23、25 章
數位主線	識別碼一致嗎？KPI 與追溯能由事件產生嗎？	第 20、23 章

本章概念	關鍵提問	回顧的章節
學生與 PoC	方案處理了瓶頸嗎？學生與試行一致嗎？	第 19 ~ 21 章
時程	要徑上是什麼？量測何時開始？	第 27 章
文件與反思	別人能重現與接手嗎？學到了什麼？	第 36 章

章末小結

- 學習工廠以真實的製程、產品與價值鏈進行教學與研究，1994 年出現於美國，2007 年起在歐洲擴展，2017 年成立國際學習工廠協會。本章的五站教學產線基準模型中，產出約 33.5 件 / 小時、良品約 31.7 件，CNC 加工的負荷約 98% 是瓶頸，在製品與生產週期符合利特爾法則。
- 企業出題的第一步是把解法還原成問題，並以可量測的 KPI 與護欄指標定義成功。日間波動的變異係數約 10% 時，證明 8% 的改善需要基準與試行各約 25 天；只量三天的結果可能只是波動。
- 系統架構沿用本書的分層，以數位主線的一致識別碼與事件紀錄，直接計算 KPI 並進行追溯；範例在幾秒內找出振動異常期間加工的 38 件產品與相關工單和料批。AI 模組應從問題出發，並有模型卡、驗收標準與負責人。
- PoC 先在學生中比較方案、再到現場試行。範例中，處理瓶頸的刀具路徑最佳化成本效益最好（學生預測約 +8.7%）；試行 25 天的改善約 4.3 件 / 小時，信賴區間 2.4 ~ 6.3，應報告為區間而非單一數字。要徑分析顯示，量測而非程式決定專題的完成時間。
- 技術文件要讓決策者、工程師與後繼者都能使用，並確保可重現；展示從問題開始，答辯誠實面對不確定性與限制；反思把經驗轉成可遷移的能力。智慧製造是一個持續量測、理解、決策、行動、再量測的循環。

習題

一、選擇題

1. 以真實的製程與產品進行教學與研究的工廠環境稱為？（A）燈塔工廠 （B）學習工廠 （C）關

燈工廠 (D) 虛擬晶圓廠

2. 依本章，「學習工廠」一詞最早出現於哪一年？(A) 1984 (B) 2007 (C) 1994 (D) 2017
3. 改善前的現況量測稱為？(A) 目標 (B) 護欄 (C) 試行 (D) 基準
4. 串接產品與製程全生命週期資料的資料鏈是？(A) 數位主線 (B) 區塊鏈 (C) 供應鏈 (D) 價值流
5. 以小規模實作驗證想法可行性與效益的是？(A) 量產 (B) PoC (C) 稽核 (D) 採購
6. 決定專案完成時間的工作序列稱為？(A) 寬裕 (B) 里程碑 (C) 要徑 (D) 甘特圖
7. 在改善確實存在時能檢定出來的機率稱為？(A) 顯著水準 (B) 信賴水準 (C) p 值 (D) 檢定力
8. 在製品 = 產出率 × 生產週期，稱為？(A) 利特爾法則 (B) 摩爾定律 (C) 帕累托法則 (D) 墨菲定律
9. 依本章的基準模型，教學產線的瓶頸是？(A) 上料 (B) CNC 加工 (C) 視覺檢測 (D) 包裝
10. 依本章，報告試行效益時應同時呈現？(A) 團隊照片 (B) 程式行數 (C) 信賴區間 (D) 使用的雲端服務

二、簡答題

11. 說明學習工廠的教學理念，以及 CIRP 定義中的幾個要素。
12. 學習工廠的場域設計應考慮哪些原則？
13. 為什麼要把企業出題的「解法」還原成「問題」？如何進行？
14. 好的 KPI 定義應包含哪些項目？為什麼需要護欄指標？
15. 為什麼量測天數會影響能否證明改善？如何在有限的時間內提高量測的敏感度？
16. 數位主線如何讓 KPI 計算與追溯變得容易？

17. 為什麼要先在數位孿生中比較方案，再到現場試行？

18. 公開展示與答辯應如何準備？

三、計算題

19. 產出 33.5 件 / 小時，平均生產週期 786 秒，依利特爾法則在製品約為多少？

20. 瓶頸站的平均工時 95 秒，理論上限為每小時多少件？若實際產出 33.5 件，達成率約為多少？

21. 日間標準差 3.2 件 / 小時，要偵測 2.5 件 / 小時的改善 ($\alpha = 0.05$ 、檢定力 80%，z 值合計取 2.8)，基準與試行各約需幾天？

22. 某方案成本 15 萬元，使良品產出提升 8.7%；另一方案成本 25 萬元，提升 6.0%。每萬元提升的百分點各為多少？

23. 試行平均 35.1、基準平均 30.8 件 / 小時，差多少？相對改善約多少百分比？

24. 差值 4.3，標準誤 0.98，95% 信賴區間約為多少？

25. 專題的要徑工作依序為 1、1、5、1、3、5、1、1 週，總工期為多少週？若試行縮短為 3 週呢？

26. 良品產出提升 4.3 件 / 小時，每天運轉 16 小時、每月 22 天，每件邊際貢獻 40 元，每月效益約為多少？投資 15 萬元約幾個月回收？

四、申論與設計題

27. 為你所在學校或地區的學習工廠，設計一條教學產線與其資料架構，說明產品、站別、設備、資料與安全的設計。

28. 評論以下說法：「總整專題的成果，應以使用的技術是否先進來評價。」

29. 若孿生預測的改善為 8.7%，試行結果為 14.1% (信賴區間 7.8%~20.5%)，你會如何向企業報告？為什麼兩者會不同？

五、是非題

30. 只要試行三天的產出提升 10%，就可以確定改善有效。

31. 非瓶頸站的改善通常不會提高產線的產出。

- 32. 技術文件應讓他人能重現結果。
- 33. 數位孿生的結論不需要以試行驗證。
- 34. 量測的時程常會決定專題的完成時間。
- 35. 答辯時承認專題的限制會降低說服力。

六、進階挑戰題

- 36. 擴充 38.1 節的基準模型：加入多品項與換線時間、作業員的配置與排班，並以實際資料校正，評估模型的誤差。
- 37. 將 38.3 節的數位主線實作為資料庫與 API，並以第 28、29 章的方法建立一個能回答「這批產品的來龍去脈」的知識助理或代理。
- 38. 以本書各篇的內容，為一家中小企業設計三年的智慧製造路線圖，並以學習工廠作為人才培育與方案驗證的場域。

七、補充題

- 39. 列出 38.4 節中，在數位孿生中比較的五個方案。
- 40. 列出表 38-3 中 KPI 定義應包含的項目。

提示與參考解答

- 1. B。
- 2. C。
- 3. D。
- 4. A。
- 5. B。
- 6. C。
- 7. D。
- 8. A。

9. B。

10. C。

11. 參考：做中學，在真實產線上量測、分析、改善並承擔後果。CIRP 定義強調真實的流程、可變更的場域、類似真實價值鏈的環境、實體產品的製造，以及讓學習者主動參與的教學設計。

12. 參考：產品簡單但有變異、設備開放可讀取與修改、安全功能與教學分離、網路分區、資料可擷取與同步至孿生。

13. 參考：解法可能不對應真正的問題。訪談不同角色、到現場觀察與量測，以「誰的痛點、痛點的代價、成功的樣子」整理需求，並寫下不做什麼。

14. 參考：名稱、公式、資料來源、量測頻率、基準值、目標值、負責人。護欄指標避免只優化單一指標而犧牲品質或生產週期。

15. 參考：改善小於日間波動時，需要更多天數才能分辨。可固定品項、排除干擾、選擇效果更大的方案，或使用更敏感的指標（如單件工時）。

16. 參考：一致的識別碼與事件紀錄使 KPI 可由事件直接計算，追溯只是資料查詢，不需翻閱紙本與人工比對。

17. 參考：孿生能快速、低成本地比較多個方案並找出處理瓶頸者；但結論取決於模型假設，需以試行的真實資料驗證。

18. 參考：從問題與代價開始，呈現基準、方案選擇、含不確定性的結果、效益與成本、限制與下一步；準備示範的備案；預想常見問題並誠實回答。

19. $33.5 \div 3,600 \times 786 \approx 7.3$ 件。

20. $3,600 \div 95 \approx 37.9$ 件； $33.5 \div 37.9 \approx 88\%$ 。

21. $2 \times (2.8 \times 3.2 \div 2.5)^2 \approx 2 \times 12.8 \approx 25.7$ ，約 26 天（程式以精確的 z 值計算為 25 天）。

22. $8.7 \div 15 \approx 0.58$ ； $6.0 \div 25 = 0.24$ 。

23. 4.3 件 / 小時； $4.3 \div 30.8 \approx 14\%$ 。

24. $4.3 \pm 1.96 \times 0.98 \approx 2.4 \sim 6.2$ 。

25. 18 週；16 週。

26. $4.3 \times 16 \times 22 \times 40 \approx 60,544$ 元，約 6.1 萬元； $15 \div 6.1 \approx 2.5$ 個月。

27. 參考：產品宜簡單而有變異；站別涵蓋加工、組裝、檢測與物流；設備開放並聯網；資料進入 MES 與孿生；安全功能獨立、網路分區。

28. 參考：不同意。應以是否解決真實問題、效益是否以可信的方法證明、成果能否重現與延續來評價；技術是手段而非目的。

29. 參考：報告改善確實存在，幅度約在 8%~20% 之間；說明差異可能來自孿生的假設、試行期間的品項與干擾、隨機波動；建議以更長期或現場的資料持續追蹤。

30. 否。

31. 是。

32. 是。

33. 否。

34. 是。

35. 否。

36. 提示：換線時間與品項組合會改變瓶頸的有效產能；以實際的事件資料估計工時分布並比較模型與實際的 KPI。

37. 提示：以序號為核心建立圖或關聯資料模型，代理的工具包括事件查詢、追溯與 KPI 計算，並遵守第 29 章的權限與核准原則。

38. 提示：可依第 37 章的四個階段規劃，並對應各篇的技術與治理要求。

39. 加大緩衝、CNC 預測維護、CNC 刀具路徑最佳化、視覺檢測回饋、預測維護加刀具路徑最佳化。

40. 名稱、公式、資料來源、量測頻率、基準值、目標值、負責人。